

Introdução aos Processos Estocásticos - VAs Contínuas Múltiplas

Eduardo M. A. M. Mendes

DELT - UFMG

Programa de Pós-Graduação em Engenharia Elétrica

Universidade Federal de Minas Gerais

emmendes@cpdee.ufmg.br

Serão consideradas 2 VAs, X e Y , conjuntamente distribuídas - significando que o experimento original, espaço amostral Ω , é mapeado em dois números $X(s) = x$ e $Y(s) = y$ onde $s \in \Omega$.

Resultados : $(x, y) \rightarrow \Omega_{x,y} = \{(x, y) : -\infty < x < \infty, -\infty < y < \infty\}$

Exemplo: Dardo - achar $P(\text{centro do alvo}) = P\left(\sqrt{x^2 + y^2} < \frac{1}{4}\right)$

- Se o lançador for um amador, provavelmente os lançamentos estarão em toda a área do alvo.
- Se o lançador for um expert, provavelmente os lançamentos estarão concentrados em uma área pequena perto do centro do alvo.

Introdução (cont.)




Figura 1: a) amador e b) expert

$$\begin{aligned} P(\text{centro do alvo}) &= \frac{\text{Área do centro do alvo}}{\text{Área Total}} \\ &= \frac{\pi \left(\frac{1}{4}\right)^2}{\pi(1)^2} = \frac{1}{16} \end{aligned}$$

Introdução (cont.)

Problema: Como achar a probabilidade para o campeão?

$$P_c \gg P_a$$

Podemos olhar o caso do amador como

$$P(\text{centro do alvo}) = \underbrace{\pi \left(\frac{1}{4}\right)^2}_{\text{Área}} \times \underbrace{\frac{1}{\pi}}_{\text{Altura}}$$

Definindo

$$p_{X,Y}(x,y) = \begin{cases} \frac{1}{\pi}, & x^2 + y^2 < 1 \\ 0 & \text{caso contrário} \end{cases}$$

podemos achar o mesmo volume usando

$$\begin{aligned}P(\text{centro do alvo}) &= \int \int_A p_{X,Y}(x,y) dx dy \\&= \int \int_{\{(x,y): x^2+y^2 \leq (\frac{1}{4})^2\}} \frac{1}{\pi} dx dy \\&= \frac{1}{\pi} \times \pi \left(\frac{1}{4}\right)^2 \\&= \frac{1}{16}\end{aligned}$$

Introdução (cont.)




Figura 2: Interpretação Geométrica

Exemplo:

$$p_{X,Y}(x,y) = \begin{cases} 4(1 - |2x - 1|)(1 - |2y - 1|), & 0 \leq x \leq 1, 0 \leq y \leq 1 \\ 0, & \text{caso contrário} \end{cases}$$




Figura 3: 3D - PDF conjunta

Introdução (cont.)




Figura 4: Contorno - PDF conjunta

Para verificar se é uma PDF válida

$$\begin{aligned} P(S_{X,Y}) &= \int_0^1 \int_0^1 p_{X,Y}(x,y) dx dy \\ &= \int_0^1 \int_0^1 4(1 - |2x - 1|)(1 - |2y - 1|) dx dy \\ &= \int_0^1 2(1 - |2x - 1|) dx \int_0^1 2(1 - |2y - 1|) dy \end{aligned}$$

Introdução (cont.)

Se $p_{X,Y}$ não pudesse ser separada em $g(x) \times g(y)$ a solução seria muito mais difícil. No nosso caso podemos facilmente ver que:

$$\int_0^1 g(x) dx = 1$$

logo

$$P(S_{X,Y}) = 1$$

Em geral é difícil determinar a integral dupla a não ser que:

- $p_{X,Y}$ seja separável.
- a área de integração seja retangular.

Três dimensões a volume não nulo requer uma área (base) não nula

Introdução (cont.)




Figura 5: Exemplos de eventos com probabilidade zero para variáveis X e Y contínuas distribuídas conjuntamente.

Introdução (cont.)

Exemplo: PDF gaussiana bivariada

$$p_{X,Y}(x,y) = \frac{1}{2\pi\sqrt{1-\rho^2}} e^{-\frac{x^2-2\rho xy+y^2}{2(1-\rho^2)}} \quad -\infty < x < \infty, -\infty < y < \infty$$

onde $-1 < \rho < 1$. Os contornos de PDF constante são dados por

$$\underbrace{p_{X,Y}(x,y)}_{x^2-2\rho xy+y^2} = c$$

se $\rho = 0 \rightarrow$ círculo senão $\rho \neq 0 \rightarrow$ elipse.

$$|\rho| < 1 \rightarrow x^2 - 2\rho xy + y^2 = r^2 > 0$$

$$x^2 - 2\rho xy + y^2 = \begin{bmatrix} x \\ y \end{bmatrix}^T \begin{bmatrix} 1 & -\rho \\ -\rho & 1 \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix}$$

com $\det(\bullet) = 1 - \rho^2 > 0$.

- Para uma VA distribuída conjuntamente, a PDF marginal é a pdf que quando integrada leva a $p[a \leq x \leq b]$.

Repare que

$$\begin{aligned} p[a \leq x \leq b] &= P[a \leq x \leq b, -\infty < y < \infty] \\ &= \int \int_A p_{X,Y}(x,y) dx dy \\ &= \int_{-\infty}^{\infty} \int_a^b p_{X,Y}(x,y) dx dy \\ &= \int_a^b \underbrace{\int_{-\infty}^{\infty} p_{X,Y}(x,y) dy}_{p_X(x)} dx \end{aligned}$$

PDFs Marginais (cont.)

Exemplo: Gaussiana Bivariada padrão

$$p_X(x) = \int_{-\infty}^{\infty} p_{X,Y}(x,y) dy = \int_{-\infty}^{\infty} \frac{1}{2\pi\sqrt{1-\rho^2}} e^{-\frac{1}{2(1-\rho^2)}(x^2-2\rho xy+y^2)} dy$$

mas

$$\begin{aligned} x^2 - 2\rho xy + y^2 &= y^2 - 2\rho xy + \rho x^2 - \rho x^2 + x^2 \\ &= (y - \rho x)^2 + (1 - \rho^2)x^2 \end{aligned}$$

logo

$$\begin{aligned} p_X(x) &= \int_{-\infty}^{\infty} \frac{1}{2\pi\sqrt{1-\rho^2}} e^{-\frac{1}{2(1-\rho^2)}(y-\rho x)^2} \times e^{-\frac{1}{2(1-\rho^2)}(1-\rho^2)x^2} dy \\ &= \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}x^2} \underbrace{\int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2\sigma^2}(y-\mu)} dy}_{=1} \quad \begin{cases} \sigma^2 = 1 - \rho^2 \\ \mu = \rho x \end{cases} \\ &= \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}x^2} \rightarrow X \sim N(0, 1) \end{aligned}$$

- Lembrando

$$P(A \cap B) = P(A) \times P(B)$$

$$P(A|B) = \frac{P(A \cap B)}{P(B)} = P(A)$$

ou seja, o conhecimento do evento B não muda a probabilidade de ocorrência do evento A .

- Duas VAs contínuas são independentes se para todo os eventos A e B

$$P[x \in A, y \in B] = P(x \in A) \times P(y \in B)$$

ou seja

$$p_{X,Y}(x, y) = p_X(x) \times p_Y(y)$$

- Exemplo: VA exponencial

$$p_{X,Y}(x,y) = \begin{cases} e^{-(x+y)} & x \geq 0, y \geq 0 \\ 0 & \text{caso contrário} \end{cases}$$

e

$$\begin{aligned} p_{X,Y} &= e^{-(x+y)} u(x) u(y) \quad (\text{degrau}) \\ &= \underbrace{e^{-x} u(x)}_{p_X(x) \rightarrow X \sim \exp(1)} \times \underbrace{e^{-y} u(y)}_{p_Y(y) \rightarrow Y \sim \exp(1)} \end{aligned}$$

Para ser independente é preciso que cada fator seja uma PDF válida ($\int = 1$).

Independência (cont.)

- Exemplo

$$p_{X,Y}(x,y) = \begin{cases} e^{-(x+y)} & x \geq 0, y \geq 0 \text{ e } y < x \\ 0 & \text{caso contrário} \end{cases}$$

Não há como escrever como degrau.

- Exemplo: Gaussiana Bivariada com $\rho = 0$.

$$\begin{aligned} P_{X,Y}(x,y) &= \frac{1}{2\pi\sqrt{1-\rho^2}} e^{-\frac{1}{2(1-\rho^2)}(x^2-2\rho xy+y^2)} \\ &= \frac{1}{2\pi} e^{-\frac{1}{2}(x^2+y^2)} \\ &= \underbrace{\frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}x^2}}_{p_X(x)} \times \underbrace{\frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}y^2}}_{p_Y(y)} \end{aligned}$$

repare que são independentes

Determinar a PDF de

$$Z = g(X, Y)$$

Problema Típico: Se $X \sim N(0, 1)$ e $Y \sim N(0, 1)$ são independentes, qual é a PDF da distância de $(x, y) = (0, 0)$ ou

$$Z = \sqrt{X^2 + Y^2}?$$

- **Solução** - usando a CDF: Encontrar $F_Z(z)$ e

$$p_Z(z) = \frac{dF_Z(z)}{dz}$$

- **Extensão** de

$$p_Y(y) = p_X(g^{-1}(y)) \left| \frac{dg^{-1}(y)}{dy} \right|$$

- Exemplo: Soma de VAs $U(0, 1)$ independentes


$$X = U_1 + U_2$$

$$F_X(x) = \int \int_{\{(U_1, U_2): u_1 + u_2 \leq x\}} p_{U_1, U_2}(u_1, u_2) du_1 du_2$$

onde

$$p_{U_1, U_2} = p_{U_1} \times p_{U_2} \text{ (Independência)} = \begin{cases} 1 & 0 < u_1 < 1, 0 < u_2 < 1 \\ 0 & \text{caso contrário} \end{cases}$$

Solução CDF (cont.)




(a) $0 \leq x < 1$

Figura 6: A reta $u_1 + u_2 = x$ é válida para $0 < x < 1$
No caso da figura acima

$$\text{Área} = \begin{cases} \frac{1}{2}x^2 & 0 \leq x \leq 1 \\ 0 & x < 0 \end{cases}$$

Solução CDF (cont.)



(b) $1 \leq x \leq 2$

Figura 7: A reta $u_1 + u_2 = x$ é válida para $1 < x < 2$

Solução CDF (cont.)

No caso da figura acima

$$\text{Área} = \left\{ 1 - \frac{1}{2}(2 - x)^2 \right.$$

Para $x > 2$

$$\text{Área} = \left\{ 1 \right.$$

Logo

$$F_X(x) = \begin{cases} 0, & x < 0 \\ \frac{1}{2}x^2, & 0 \leq x < 1 \\ 1 - \frac{1}{2}(2 - x)^2, & 1 \leq x \leq 2 \\ 1, & x > 2 \end{cases}$$

e

$$p_X(x) = \frac{dF_X(x)}{dx} = \begin{cases} 0, & x < 0 \\ x, & 0 \leq x < 1 \\ 2 - x, & 1 \leq x \leq 2 \\ 0, & x > 2 \end{cases}$$




Figura 8: PDf da soma de duas variáveis independentes $U(0, 1)$. Convolução

- $Z = X + Y$ onde X e Y são independentes.

$$F_Z(z) = P(Z \leq z) = P(x + y \leq z)$$

Solução CDF (cont.)

- Fixar z e determinar todos os valores de (x, y) para os quais $x + y \leq z$
 - Região de Integração

$$\begin{aligned}F_z(z) &= \int_{-\infty}^{\infty} \int_{-\infty}^{z-x} p_{X,Y}(x, y) dx dy \\&= \int_{-\infty}^{\infty} \int_{-\infty}^{z-x} p_X(x) \times p_Y(y) dx dy \\&= \int_{-\infty}^{\infty} p_X(x) \underbrace{\int_{-\infty}^{z-x} p_Y(y) dy}_{F_Y(z-x)} dx\end{aligned}$$

$$\frac{dF_Z(z)}{dz} = \int_{-\infty}^{\infty} p_X(x) \frac{dF_Y(z-x)}{dz} dx$$

\downarrow

$$p_Z(z) = \int_{-\infty}^{\infty} p_X(x) \times p_Y(z-x) dx$$

ou

$$p_Z(z) = p_X * p_Y$$



$$\begin{aligned}W &= X \\ Z &= g(X, Y)\end{aligned}$$

Encontrar a PDF conjunta de (W, Z)

$$p_{W,Z} \left\{ \begin{array}{l} W = h(X, Y) \rightarrow W = X \\ Z = g(X, Y) \rightarrow Z = g(X, Y) \end{array} \right.$$

Solução Variável Auxiliar (cont.)

- Usando a notação matricial, podemos escrever o seguinte

$$\begin{bmatrix} W \\ Z \end{bmatrix} = \underbrace{\begin{bmatrix} a & b \\ c & d \end{bmatrix}}_{G \rightarrow G^{-1} \text{ existe}} \begin{bmatrix} X \\ Y \end{bmatrix}$$

Obs.: Lembrando que para o caso $Y = 2X$, onde $X \sim U(1, 2)$

$$\begin{aligned} p_Y(y) &= p_X(g^{-1}(y)) \left| \frac{dg^{-1}(y)}{dy} \right| \\ &= p_X\left(\frac{y}{2}\right) \times \frac{1}{2} \end{aligned}$$

2D - Compressão, expansão e rotação.

Solução Variável Auxiliar (cont.)

- Exemplo: Considere $U_1 \sim U(0, 1)$ e $U_2 \sim U(0, 1)$ e

$$\begin{bmatrix} X_1 \\ X_2 \end{bmatrix} = \begin{bmatrix} U_1 \\ \frac{U_1+U_2}{2} \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ \frac{1}{2} & \frac{1}{2} \end{bmatrix} \begin{bmatrix} U_1 \\ U_2 \end{bmatrix}$$




Figura 9: Mapa das Transformações.

Solução Variável Auxiliar (cont.)

$$\begin{bmatrix} 1 & 0 \\ \frac{1}{2} & \frac{1}{2} \end{bmatrix} \rightarrow \det(\bullet) = 1 \times \frac{1}{2} - 0 \times \frac{1}{2} = \frac{1}{2}$$

e portanto

$$p_{W,Z}(w, z) = p_{X,Y} \left(G^{-1} \begin{bmatrix} w \\ z \end{bmatrix} \right) |\det(G^{-1})|$$

- Exemplo $\begin{cases} W = \sigma_W X \\ Z = \sigma_Z Y \end{cases} \quad X, Y \sim \text{Gaussiana Bivariada}$

Podemos escrever

$$\begin{bmatrix} W \\ Z \end{bmatrix} = \begin{bmatrix} \sigma_W & 0 \\ 0 & \sigma_Z \end{bmatrix} \begin{bmatrix} X \\ Y \end{bmatrix}$$

onde

$$G^{-1} = \begin{bmatrix} \frac{1}{\sigma_W} & 0 \\ 0 & \frac{1}{\sigma_Z} \end{bmatrix} \rightarrow \det(G^{-1}) = \frac{1}{\sigma_W \sigma_Z}$$

Solução Variável Auxiliar (cont.)

e

$$G^{-1} \begin{bmatrix} W \\ Z \end{bmatrix} = \begin{bmatrix} \frac{W}{\sigma_W} \\ \frac{Z}{\sigma_Z} \end{bmatrix}$$

Calculando a probabilidade conjunta, temos

$$\begin{aligned} p_{W,Z}(w, z) &= \frac{e^{-\frac{1}{2(1-\rho^2)} \left[\left(\frac{w}{\sigma_W} \right)^2 - 2\rho \frac{w}{\sigma_W} \frac{z}{\sigma_Z} + \left(\frac{z}{\sigma_Z} \right)^2 \right]}}{2\pi \sqrt{1-\rho^2}} \frac{1}{\sigma_W \sigma_Z} \\ &= \frac{e^{-\frac{1}{2(1-\rho^2)} \left[\left(\frac{w}{\sigma_W} \right)^2 - 2\rho \frac{w}{\sigma_W} \frac{z}{\sigma_Z} + \left(\frac{z}{\sigma_Z} \right)^2 \right]}}{2\pi \sqrt{(1-\rho^2)\sigma_W^2 \sigma_Z^2}} \\ &= \frac{1}{2\pi \det^{\frac{1}{2}}(C)} e^{-\frac{1}{2} \begin{bmatrix} w \\ z \end{bmatrix}^T C^{-1} \begin{bmatrix} w \\ z \end{bmatrix}} \end{aligned}$$

Solução Variável Auxiliar (cont.)

com $-\infty < w < \infty$, $-\infty < z < \infty$ e onde

$$C = \begin{bmatrix} \sigma^2 & \rho\sigma_W\sigma_Z \\ \rho\sigma_W\sigma_Z & \sigma_Z^2 \end{bmatrix}$$

que é a matriz de covariância

Dado

$$\begin{aligned}W &= g(X, Y) \\ Z &= h(X, Y)\end{aligned}$$

$$p_{W,Z}(w, z) = p_{X,Y}(g^{-1}(w, z), h^{-1}(w, z)) \times \underbrace{\left| \det \frac{\partial(x, y)}{\partial(w, z)} \right|}_{\text{Jacobiano}}$$

onde

$$\begin{aligned}x &= g^{-1}(w, z) \\ y &= h^{-1}(w, z)\end{aligned}$$

Mais de Transformações (cont.)

- Exemplo: Considere

$$\begin{array}{llll} X & \sim & N(0,1) & W = X \\ Y & \sim & N(0,1) & Z = \frac{Y}{X} \end{array}$$

Solução

$$\begin{array}{ll} x & = w \\ y & = wz \end{array}$$

logo

$$\frac{\partial(x,y)}{\partial(w,z)} = \begin{bmatrix} \frac{\partial x}{\partial w} & \frac{\partial x}{\partial z} \\ \frac{\partial y}{\partial w} & \frac{\partial y}{\partial z} \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ z & w \end{bmatrix}$$

e

$$\left| \det \left(\frac{\partial(x,y)}{\partial(w,z)} \right) \right| = |w|$$

Podemos assim calcular

$$\begin{aligned} p_{W,Z}(w, z) &= \frac{1}{2\pi} e^{-\frac{1}{2}(x^2+y^2)} \Big|_{x=w, y=wz} \times |w| \\ &= \frac{1}{2\pi} e^{-\frac{1}{2}(w^2+w^2z^2)} \times |w| \\ &= \frac{1}{2\pi} e^{-\frac{1}{2}w^2(1+z^2)} \times |w| \end{aligned}$$

com $-\infty < w < \infty$ e $-\infty < z < \infty$.

Mais de Transformações (cont.)

Para a PDF de $\frac{Y}{X}$

$$\begin{aligned}p_Z(z) &= \int_{-\infty}^{\infty} \frac{1}{2\pi} e^{-\frac{1}{2}w^2(1+z^2)} \times |w| dw \\&= 2 \int_0^{\infty} \frac{1}{2\pi} e^{-\frac{1}{2}w^2(1+z^2)} \times |w| dw \\&= \frac{1}{\pi} \int_0^{\infty} w e^{-\frac{1}{2}w^2(1+z^2)} dw \\&= \frac{1}{\pi} \left. \frac{e^{-\frac{1}{2}(1+z^2)w^2}}{-(1+z^2)} \right|_0^{\infty} \\&= \frac{1}{\pi(1+z^2)}\end{aligned}$$

que é a distribuição de **Cauchy**.

Mais de Transformações (cont.)

- **Exemplo:** Se $X \sim N(0, \sigma^2)$, $Y \sim N(0, \sigma^2)$ e X e Y são independentes então

$$\begin{aligned} R &= \sqrt{x^2 + y^2}, & R &\geq 0 \\ \Theta &= \arctg\left(\frac{Y}{X}\right), & 0 &\leq \theta < 2\pi \end{aligned}$$

Repare que existe aqui uma transformação de variáveis e que $x = r \cos(\theta)$ e $y = r \sin(\theta)$, logo

$$\det \left(\frac{\partial(x, y)}{\partial(r, \theta)} \right) = \det \left(\begin{bmatrix} \cos(\theta) & -r \sin(\theta) \\ \sin(\theta) & r \cos(\theta) \end{bmatrix} \right) = r \geq 0$$

A conjunta de (x, y) pode ser escrita da seguinte maneira

$$p_{X,Y} = p_X(x) \times p_Y(y) = \frac{1}{2\pi\sigma^2} e^{-\frac{1}{2\sigma^2}(x^2+y^2)}$$

Finalmente, podemos escrever

$$p_{R,\Theta} = \begin{cases} \underbrace{\frac{r}{\sigma^2} e^{-\frac{1}{2} \frac{r^2}{\sigma^2}}}_{p_R(r)} \underbrace{\frac{1}{2\pi}}_{p_\Theta(\theta)} & r \geq 0 \\ 0 & r < 0 \end{cases}$$

onde R tem distribuição de Rayleigh e $\theta \sim U(0, 2\pi)$ (R e θ são independentes).

- O valor esperado é

$$E \left[\begin{bmatrix} X \\ Y \end{bmatrix} \right] = \begin{bmatrix} E[X] \\ E[Y] \end{bmatrix}$$

- Se $E(Z)$ se $Z = g(X, Y)$?

$$E(Z) = \int_{-\infty}^{\infty} zp_Z(z)dz \quad \rightarrow \text{cálculo de } p_Z(z)$$

ou

$$E(Z) = E[g(X, Y)] = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} g(x, y)p_{X,Y}(x, y)dxdy$$

- **Exemplo:** VAs independentes

$$\begin{aligned}E_{X,Y}(XY) &= \int \int xyp_{X,Y}(x,y)dx dy \\&= \int \int xyp_X(x)p_Y(y)dx dy \\&= \int xp_X(x)dx \int yp_Y(y)dy \\&= E_X(x) \times E_Y(y)\end{aligned}$$

- Covariância

$$\text{cov}(x,y) = E_{X,Y} [(x - E_X(x))(y - E_Y(y))] = E_{X,Y}(xy) - E_X(x) \times E_Y(y)$$

- **Exemplo:** Gaussiana Bivariada

$$E_X(x) = E_Y(y) = 0$$

e

$$\text{cov}(X, Y) = E_{X,Y}(XY) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} xy \frac{1}{2\pi\sqrt{1-\rho^2}} e^{-\frac{1}{2}(x^2-2\rho xy+y^2)} dx dy$$

Note que

$$\rho = \rho_{X,Y} = \frac{\text{cov}(X, Y)}{\sqrt{\text{Var}(X) \times \text{Var}(Y)}}$$

repare que podemos fazer a predição de Y a partir de X .

$$X(s) = \begin{bmatrix} X_1(s) \\ X_2(s) \\ \vdots \\ X_N(s) \end{bmatrix}$$

A PDF conjunta é:

$$\begin{cases} p_{X_1, \dots, X_N}(x_1, x_2, \dots, x_n) & \geq 0 \\ \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} p_{X_1, \dots, X_N}(x_1, x_2, \dots, x_n) dx_1 dx_2 \dots dx_N & = 1 \end{cases}$$

$$P(A) = \int \int \cdots \int_A p_{\underline{X}}(\underline{x}) d\underline{x}$$

VAs Multidimensionais (cont.)

- A PDF multidimensional mais importante é a gaussiana

$$p_{\underline{X}}(\underline{x}) = \frac{1}{\pi^{\frac{N}{2}} \det^{\frac{1}{2}}(\underline{C})} e^{-\frac{1}{2}(\underline{x}-\underline{\mu})^T \underline{C}^{-1}(\underline{x}-\underline{\mu})}$$

onde

$$\underline{\mu} = E_{\underline{X}}(\underline{x}) = \begin{bmatrix} E_{X_1}(x_1) \\ \vdots \\ E_{X_N}(x_N) \end{bmatrix}$$

e

$$\underline{C} = \begin{bmatrix} \text{Var}(X_1) & \dots & \text{cov}(X_1, X_3) & \dots & \text{cov}(X_1, X_N) \\ \text{cov}(X_2, X_1) & \text{Var}(X_2) & \dots & \dots & \text{cov}(X_2, X_N) \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ \text{cov}(X_N, X_1) & \dots & \dots & \dots & \text{Var}(X_N) \end{bmatrix}$$

VAs Multidimensionais (cont.)

Podemos escrever

$$\underline{X} \sim N(\underline{\mu}, \underline{C})$$

$$\underline{C} = E_{\underline{X}} [(\underline{x} - \underline{\mu})(\underline{x} - \underline{\mu})^T]$$

Para achar a marginal $p_{X_1}(x_1)$

$$p_{X_1} = \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} p_{\underline{X}}(\underline{x}) dx_2 \dots dx_N$$

$$p_{X_1, X_2}(x_1, x_2) = \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} p_{\underline{X}}(\underline{x}) dx_3 \dots dx_N$$

X_1, X_2, \dots, X_N são independentes se e somente se

$$p_{X_1, X_2, \dots, X_N}(x_1, x_2, \dots, x_N) = p_{X_1}(x_1) \times p_{X_2}(x_2) \dots p_{X_N}(x_N)$$

Exemplo: Independência de $N(\underline{\mu}, \underline{C})$. Basta verificar \underline{C} !

VAs Multidimensionais (cont.)

- Se \underline{C} é diagonal - não correlacionadas e por serem gaussianas, independentes.

$$\underline{C} = \begin{bmatrix} \sigma_1^2 & 0 & \dots & \dots & 0 \\ 0 & \dots & \dots & \dots & \dots \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & \dots & \dots & \dots & \sigma_N^2 \end{bmatrix} \longrightarrow \det(\underline{C}) = \prod_{i=1}^N \sigma_i^2$$

- Calculando a inversa

$$\underline{C}^{-1} = \begin{bmatrix} \frac{1}{\sigma_1^2} & 0 & \dots & \dots & 0 \\ 0 & \dots & \dots & \dots & \dots \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & \dots & \dots & \dots & \frac{1}{\sigma_N^2} \end{bmatrix}$$

VAs Multidimensionais (cont.)

- Finalmente

$$\begin{aligned} p_{\underline{X}}(\underline{x}) &= \frac{1}{\pi^{\frac{N}{2}} \left(\prod_{i=1}^N \sigma_i^2 \right)^{\frac{1}{2}}} e^{-\frac{1}{2} (\underline{x} - \underline{\mu})^T \underline{C}^{-1} (\underline{x} - \underline{\mu})} \\ &= \frac{1}{\pi^{\frac{N}{2}} \left(\prod_{i=1}^N \sigma_i^2 \right)^{\frac{1}{2}}} e^{-\frac{1}{2} \sum_{i=1}^N \frac{(x_i - \mu_i)^2}{\sigma_i^2}} \\ &= \prod_{i=1}^N \underbrace{\frac{1}{\sqrt{2\pi\sigma_i^2}} e^{-\frac{1}{2\sigma_i^2} (x_i - \mu_i)^2}}_{N(\mu_i, \sigma_i^2)} \\ &= \prod_{i=1}^N p_{X_i}(x_i) \end{aligned}$$

$$\begin{aligned}Y_1 &= g_1(X_1, X_2, \dots, X_N) \\Y_2 &= g_2(X_1, X_2, \dots, X_N) \\&\vdots \\Y_N &= g_N(X_1, X_2, \dots, X_N)\end{aligned}$$

Se a transformação for $1 \leftrightarrow 1$

$$p_{Y_1, Y_2, \dots, Y_n}(y_1, y_2, \dots, y_n) = p_{X_1, X_2, \dots, X_n}(g_1^{-1}(y), g_2^{-1}(y), \dots, g_n^{-1}(y)) \underbrace{\left| \left(\frac{\partial(x_1, x_2, \dots, x_n)}{\partial(y_1, y_2, \dots, y_n)} \right) \right|}_{\text{Jacobiano}}$$

Mais Transformações (cont.)

Exemplo: $X \sim N(\underline{\mu}, \underline{C})$. Considere que

$$\underline{Y} = \underline{G}\underline{X} \longrightarrow \underline{X} = \underline{G}^{-1}\underline{Y}$$

Solução:

$$\begin{aligned} p_{\underline{Y}}(\underline{y}) &= p_{\underline{X}}(\underline{G}^{-1}\underline{y}) \times |\det(\underline{G}^{-1})| \\ &= \frac{1}{(2\pi)^{\frac{N}{2}} \det^{\frac{1}{2}}(\underline{C})} e^{-\frac{1}{2}(\underline{G}^{-1}\underline{y} - \underline{\mu})^T \underline{C}^{-1}(\underline{G}^{-1}\underline{y} - \underline{\mu})} \times |\det(\underline{G}^{-1})| \\ &= \frac{1}{(2\pi)^{\frac{N}{2}} \det^{\frac{1}{2}}(\underline{C}) |\det(\underline{G})|} e^{-\frac{1}{2}(\underline{G}^{-1}(\underline{y} - \underline{G}\underline{\mu}))^T \underline{C}^{-1}(\underline{G}^{-1}(\underline{y} - \underline{G}\underline{\mu}))} \end{aligned}$$

mas

$$|\det(\underline{G})| = \sqrt{\det^2(\underline{G})} = \sqrt{\det(\underline{G})\det(\underline{G}^T)}$$

e

$$(\underline{G}^{-1}(\underline{y} - \underline{G}\underline{\mu}))^T = (\underline{y} - \underline{G}\underline{\mu})^T (\underline{G}^{-1})^T$$

Mais Transformações (cont.)

Portanto

$$p_{\underline{Y}}(y) = \frac{1}{(2\pi)^{\frac{N}{2}} \det^{\frac{1}{2}}(\underline{C}\underline{G}\underline{G}^T)} e^{-\frac{1}{2}(\underline{y}-\underline{G}\underline{\mu})^T \underbrace{(\underline{G}^{-1})^T \underline{C}^{-1} \underline{G}^{-1}}_{(\underline{G}\underline{C}\underline{G}^T)^{-1}} (\underline{y}-\underline{G}\underline{\mu})}$$
$$\underline{Y} \sim N(\underline{G}\underline{\mu}, \underline{G}\underline{C}\underline{G}^T)$$

Mais Valores Esperados

$$E_{\underline{X}}(\underline{x}) = E_{X_1, X_2, \dots, X_N} \begin{bmatrix} X_1 \\ \vdots \\ X_N \end{bmatrix} = \begin{bmatrix} E_{X_1}(x_1) \\ \vdots \\ E_{X_N}(x_N) \end{bmatrix}$$

e

$$E_{X_1, \dots, X_N} [g(X_1, \dots, X_N)] = \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} g(X_1, \dots, X_N) p_{X_1, \dots, X_N}(x_1, \dots, x_N) dx_1 \dots dx_N$$

Exemplo: Média de VAs IID (mesma PDF marginal). Considere

$$p_{X_1} = p_{X_2} = \dots = p_{X_N} = \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}x_i^2}$$

e

$$E(x_i) = \mu$$

Mais Valores Esperados (cont.)

O objetivo é lidar com

$$\bar{X} = \frac{1}{N} \sum_{i=1}^N X_i$$

Solução

- Média

$$E_{X_1, X_2, \dots, X_N}(\bar{X}) = \frac{1}{N} \sum_{i=1}^N E_{X_i}(X_i) = \mu$$

- Variância

$$\begin{aligned} \text{Var}(\bar{X}) &= \sum_{i=1}^N \frac{1}{N^2} \text{Var}(X_i) \\ &= \frac{1}{N^2} \sum_{i=1}^N \sigma^2 \\ &= \frac{\sigma^2}{N} \end{aligned}$$

Note que $N \rightarrow \infty \rightarrow \text{Var}(\bar{X}) = 0$ e $\bar{X} \rightarrow \mu$