

# Introdução aos Processos Estocásticos - Desigualdades e Convergência

Eduardo M. A. M. Mendes

DELT - UFMG  
Programa de Pós-Graduação em Engenharia Elétrica  
Universidade Federal de Minas Gerais  
[emmendes@cpdee.ufmg.br](mailto:emmendes@cpdee.ufmg.br)

- A seguir serão descritas as várias desigualdades usadas no contexto de probabilidade e processos estocásticos.
- Serão mencionadas também as definições de convergência.

# Desigualdade de Hölder

- Se  $p$  e  $q$  são números reais maiores do que 1 com  $\frac{1}{p} + \frac{1}{q} = 1$  e se as variáveis aleatórias  $X$ ,  $Y$  e  $|X|^p$ ,  $|Y|^q$  são integráveis, então

$$E(|XY|) \leq (E(|X|^p))^{\frac{1}{p}} (E(|Y|^q))^{\frac{1}{q}}$$

- Prova:** Seja  $x$  um número positivo e considere a função  $\phi(x) = \frac{x^p}{p} + \frac{x^{-q}}{q}$ . Suponha que essa função tenha um mínimo em  $x = 1$  com  $\phi(1) = 1$ .

Substituindo  $x = \frac{b^{\frac{1}{q}}}{a^{\frac{1}{p}}} = b^{\frac{1}{q}} a^{-\frac{1}{p}}$  com  $a, b > 0$ , então

$$\begin{aligned}\phi(x) &= (ap)^{-1} b^{\frac{p}{q}} + (bq)^{-1} a^{\frac{q}{p}} \geq 1 \\ &= p^{-1} b^{\frac{(p+q)}{q}} + q^{-1} a^{\frac{(p+q)}{p}} \geq ab\end{aligned}$$

# Desigualdade de Hölder (cont.)

Como  $\frac{1}{p} + \frac{1}{q} = 1$  ou  $\frac{(p+q)}{pq} = 1$ , temos  $\frac{(p+q)}{q} = p$  e  $\frac{(p+q)}{p} = q$  e

$$ab \leq \frac{b^p}{p} + \frac{a^q}{q}$$

Substituindo

$$b = \frac{|X|}{(E(|X|^p))^{\frac{1}{p}}} \text{ e } a = \frac{|Y|}{(E(|Y|^q))^{\frac{1}{q}}}$$

na expressão logo acima, temos:

$$\begin{aligned} \frac{|X||Y|}{(E(|X|^p))^{\frac{1}{p}}(E(|Y|^q))^{\frac{1}{q}}} &\leq \frac{\left(\frac{|X|}{(E(|X|^p))^{\frac{1}{p}}}\right)^p}{p} + \frac{\left(\frac{|Y|}{(E(|Y|^q))^{\frac{1}{q}}}\right)^q}{q} \\ &\leq \frac{\frac{|X|^p}{E(|X|^p)}}{p} + \frac{\frac{|Y|^q}{E(|Y|^q)}}{q} \end{aligned}$$

# Desigualdade de Hölder (cont.)

Tomando o valor esperado obtemos

$$\frac{E(XY)}{(E(|X|^p))^{\frac{1}{p}}(E(|Y|^q))^{\frac{1}{q}}} \leq \frac{1}{p} + \frac{1}{q} = 1$$

a desigualdade segue direto da relação acima.

Fazendo  $p = q = 2$  na desigualdade de Hölder, obtemos

$$E(|XY|) \leq \sqrt{E(|X|^2)E(|Y|^2)}$$

# Desigualdade de Minkowski

- Se  $p$  é um número real com  $p \geq 1$  e se as variáveis aleatórias  $X$ ,  $Y$  e  $|X|^p$ ,  $|Y|^p$  são integráveis, então

$$(E(|X + Y|^p))^{\frac{1}{p}} \leq (E(|X|^p))^{\frac{1}{p}} + (E(|Y|^p))^{\frac{1}{p}}$$

- Prova:** Se  $p = 1$  o resultado segue da desigualdade referente ao triângulo.
- Para  $p > 1$

$$\begin{aligned} E(|X + Y|^p) &= E(|X + Y||X + Y|^{p-1}) \\ &\leq E(|X||X + Y|^{p-1}) + E(|Y||X + Y|^{p-1}) \end{aligned}$$

Usando a desigualdade de Hölder e  $\frac{1}{q} = 1 - \frac{1}{p}$ , temos

$$E(|X + Y|^p) \leq (E(|X|^p))^{\frac{1}{p}} (E(|X + Y|)^p)^{1-\frac{1}{p}} + (E(|Y|^p))^{\frac{1}{p}} (E(|X + Y|)^p)^{1-\frac{1}{p}}$$

dividindo por  $(E(|X + Y|)^p)^{1-\frac{1}{p}}$  resulta na desigualdade.

# Desigualdade de Jensen

- Se  $\phi$  é uma função convexa e contínua e se ambos  $X$  e  $\phi(X)$  são integráveis, então

$$\phi(E(X)) \leq E(\phi(X))$$

- Prova:** Se  $\phi$  é uma função convexa, podemos construir uma corda  $a_i + b_i x$  tal que

$$a_i + b_i x \leq \phi(x)$$

e

$$\sup_x (a_i + b_i x) = \phi(x)$$

logo

$$a_i + b_i X \leq \phi(X)$$

e

$$a_i + b_i E(X) \leq E(\phi(X))$$



ou

$$\sup(a_i + b_i E(X)) = \phi(E(X)) \leq E(\phi(X))$$

**Objetivo:** Achar um limite para a probabilidade a partir da variância

$$P(|X - E(X)| > \gamma)$$

O que pode ser dito se  $p_X(x)$  não pode ser integrada ou não é conhecida?

- Podemos estimar  $E(X)$  e  $Var(X)$ , então

$$P(|X - E(X)| > \gamma) \leq B$$

onde

$$B = \frac{Var(X)}{\gamma^2}$$

# Desigualdade de Chebyshev (cont.)

**Exemplo:**  $X \sim N(0, 1)$ ,  $E(X) = 0$ ,  $Var(X) = 1$ . Supondo  $\gamma = 3$ , temos

$$P(|X - 0| > 3) \leq \frac{1}{3^2} = \frac{1}{9} \approx 0,11$$

Calculando

$$P(|X| > 3) = 2P(X > 3) \approx 0,0027 < 0,11$$

limite muito conservador!

**Exemplo:** PDF Laplaciano com  $\sigma^2 = 1 = Var(X)$

$$P(|X - 0| > 3) \leq \frac{1}{9} \approx 0,11$$

Conclusão: Mesmo limite para todas as PDFs com  $Var(X) = 1$ .

# Desigualdade de Chebyshev (cont.)

- Se  $\text{Var}(X) \rightarrow 0$ , então

$$P(|X - E(X)| > \gamma) \rightarrow 0$$

para qualquer  $\gamma > 0$ .

Prova:

$$\begin{aligned}\text{Var}(X) &= \int_{-\infty}^{\infty} (x - E(X))^2 p_X(x) dx \\&= \int_{\{x: |x - E(X)| > \gamma\}} (x - E(X))^2 p_X(x) dx \\&\quad + \int_{\{x: |x - E(X)| \leq \gamma\}} (x - E(X))^2 p_X(x) dx \\&\geq \int_{\{x: |x - E(X)| > \gamma\}} (x - E(X))^2 p_X(x) dx \\&\geq \int_{\{x: |x - E(X)| > \gamma\}} \gamma^2 p_X(x) dx = \gamma^2 P(|x - E(X)| > \gamma)\end{aligned}$$

# Desigualdade de Chebyshev (cont.)

o que conclui a nossa prova.

# Teorema de Markov e Desigualdade de Chebyshev

**Teorema:** Se  $X$  é uma variável aleatória e  $g(X)$  é uma transformação de  $X$  tal que  $g(X) \geq 0$ , então, para qualquer  $K > 0$

$$P(g(X) \geq K) \leq \frac{E(g(X))}{K}$$

**Prova:** Usando a função indicadora, ou seja

$$I(g(X)) = \begin{cases} 1 & \text{se } g(X) \geq K, \\ 0 & \text{caso contrário} \end{cases}$$

Se  $g(X) \geq 0$  e  $I(g(X)) \leq 1$ , podemos escrever para a primeira condição

$$I(g(X)) \leq \frac{g(X)}{K}$$

Tomando o valor esperado

# Teorema de Markov e Desigualdade de Chebyshev (cont.)

$$\begin{aligned} E(I(g(X))) &\leq \frac{E(g(X))}{K} \\ \sum_x I(g(X)) \times p(x) &\leq \\ [1 \times P(I(g(X)) = 1)] + [0 \times P(I(g(X)) = 0)] &\leq \\ [1 \times P(g(X) \geq K)] + [0 \times P(g(X) < K)] &\leq \\ P(g(X) \geq K) &\leq \frac{E(g(X))}{K} \end{aligned}$$

# Teorema de Markov e Desigualdade de Chebyshev (cont.)

- Repare que se fizermos  $g(X) = (X - \mu)^2$  e  $K = k^2\sigma^2$ , temos

$$P((X - \mu)^2 \geq k^2\sigma^2) \leq \frac{E((X - \mu)^2)}{k^2\sigma^2} = \frac{\sigma^2}{k^2\sigma^2}$$

Podemos usar  $(X - \mu)^2 \geq k^2\sigma^2$  da seguinte maneira

$$\begin{aligned}(X - \mu)^2 \geq k^2\sigma^2 &\rightarrow (X - \mu \geq \sqrt{k^2\sigma^2}) \text{ ou } (X - \mu \leq -\sqrt{k^2\sigma^2}) \\ &\rightarrow (|X - \mu| \geq \sqrt{k^2\sigma^2}) \\ &\rightarrow (|X - \mu| \geq k\sigma)\end{aligned}$$

Logo

$$P(|X - \mu| \geq k\sigma) \leq \frac{1}{k^2}$$

que é a desigualdade de Chebyshev para  $k = \frac{\gamma}{\sigma}$ . Lembrando que  $\sigma^2$  nada mais é do que  $\text{Var}(\bullet)$ .



- Fornece um limite menos conservador comparado com Markov e Chebyshev.
- É aplicado quando a variável aleatória é a soma de várias variáveis aleatórias mutuamente independentes.
- É o limite na probabilidade de se desviar da média.
- Não se aplica a todas as distribuições. Só aplicável a soma de VAs definidas no intervalo  $[0, 1]$ .
- Não depende diretamente do número de variáveis somadas.

# Limites de Chernoff (cont.)

**Teorema:** Seja  $X_1, X_2, \dots, X_N$  variáveis aleatórias mutuamente independentes definidas no intervalo  $[0, 1]$ . Seja  $X = \sum_{j=1}^N X_j$ , então para qualquer  $c > 1$

$$P(X \geq cE(X)) \leq e^{-\alpha E(X)}$$

onde  $\alpha = c \ln(c) + 1 - c > 0$ .

**Prova:** Definindo  $R_j = X_j - E(X_j)$  para  $j = 1, 2, \dots, N$ , temos

$$-E(X_j) \leq R_j \leq 1 - E(X_j)$$

e  $E(R_j) = 0$ . Logo

# Limites de Chernoff (cont.)

$$\begin{aligned} P(X \geq cE(X)) &= P(R \geq (c-1)E(X)) \\ &= P(c^R \geq c^{(c-1)E(X)}) \\ &\leq \frac{E(c^R)}{c^{(c-1)E(X)}} \quad \text{Usando o Teorema de Markov} \end{aligned}$$

Sabemos

$$\begin{aligned} E(c^R) &= E(c^{R_1+R_2+\dots+R_N}) \\ &= E\left(\prod_{j=1}^N c^{R_j}\right) \\ &= \prod_{j=1}^N E(c^{R_j}) \quad \text{independência} \end{aligned}$$

Precisamos

1) Se  $-m \leq z \leq 1 - m$ , então

$$c^z \leq c^{-m}(1 + m(c - 1)) + z(c^{1-m} - c^{-m})$$

Repare que o lado direito descreve uma equação de uma reta que corta a curva  $c^z$  em dois pontos:  $-m$  e  $1 - m$ . Como  $c^z$  é convexa, neste intervalo, a curva se encontra abaixo da reta.

2)  $1 + m(c - 1) \leq e^{m(c-1)}$  que é consequência direta da expansão em séries de Taylor ( $1 + x \leq e^x$ ).

# Limites de Chernoff (cont.)

Podemos continuar com a prova fazendo  $m = E(X_j)$  e  $z = R_j$

$$\begin{aligned} E(c^{R_j}) &\leq E\left(c^{-m}e^{m(c-1)} + (c^{1-m} - c^{-m})R_j\right) \\ &\leq c^{-m}e^{m(c-1)} \quad \text{pois } E(R_j) = 0 \\ &\leq e^{m(c-1-\ln(c))} \end{aligned}$$

Assim

$$\begin{aligned} \prod E(c^{R_j}) &\leq \prod e^{E(X_j)(c-1-\ln(c))} \\ &\leq e^{(c-1-\ln(c)) \sum E(X_j)} \\ &\leq e^{(c-1-\ln(c))E(X)} \end{aligned}$$

Finalmente

# Limites de Chernoff (cont.)

$$\begin{aligned}P(X \geq cE(X)) &\leq \frac{e^{(c-1-\ln(c))E(X)}}{c^{(c-1)E(X)}} \\&\leq e^{E(X)(c-1-\ln(c)-c\ln(c)+\ln(c))} \\&\leq e^{E(X)(-c\ln(c)-1+c)} \\&\leq e^{-\alpha E(X)}\end{aligned}$$

onde  $\alpha = c\ln(c) + 1 - c$ .

# Limites de Chernoff - Outra Visão




Figura 1: Mostra que  $I_{[a, \infty)}(x)$  é um limite para  $e^{s(x-a)}$ .

Logo se tomarmos a esperança matemática de

$$I_{[a, \infty)}(X) \geq e^{s(X-a)}$$

temos

$$\begin{aligned} E(I_{[a, \infty)}(X)) &\geq E(e^{s(X-a)}) \\ &= e^{-sa} E(e^{sX}) \\ &= e^{-sa} \phi(s) \end{aligned}$$

# Limites de Chernoff - Outra Visão (cont.)

onde  $\phi(s)$  é função característica.

Usando o fato que toda probabilidade pode ser escrita como uma esperança matemática

$$P(X \geq A) = E(I_{[A, \infty)} X)$$

podemos escrever que

$$P(X \geq A) \geq e^{-sa} \phi(s)$$

que é válida para todo  $s > 0$ .

O limite de Chernoff é dado por

$$P(X \geq A) \geq \min_{s \geq 0} (e^{-sa} \phi(s))$$



# Exemplo

Seja  $X$  uma variável aleatória contínua com distribuição exponencial e  $\lambda = 1$ . Determine  $P(X \geq 7)$  e os limites de Markov, Chebyshev and Chernoff.

**Solução:** Sabemos que  $E(X) = \frac{1}{\lambda}$ ,  $E(X^2) = \frac{2}{\lambda^2}$ ,  $Var(X) = \frac{1}{\lambda^2}$  e  $\phi(s) = \frac{\lambda}{(\lambda - s)}$ . Logo:

## Exemplo (cont.)

$$\begin{aligned}P(X \geq 7) &= \int_7^{\infty} e^{-x} dx = e^{-7} = 0,00091 \\&\leq \frac{E(X)}{7} = \frac{1}{7} = 0,144 \quad \text{Markov} \\&\leq \frac{\text{Var}(X)}{7^2} = \frac{1}{7^2} = 0,0204 \quad \text{Chebyshev} \\&\leq \min_{s \geq 0} \frac{e^{-7s}}{1-s} = \left. \frac{e^{-7s}}{1-s} \right|_{s=6/7} = 7e^{-6} = 0.017 \quad \text{Chernoff}\end{aligned}$$

# Estimação da Média e da Variância

Nas desigualdades propostas, como por exemplo a de Chebyshev, usa-se a variância. Logo seria interessante achar uma estimativa para ela quanto para o valor esperado.

- Média

$$\hat{E}(X) = \frac{1}{M} \sum_{i=1}^M x_i \quad \text{Média Amostral}$$

Em geral

$$\hat{E}(g(x)) = \frac{1}{M} \sum_{i=1}^M g(x_i)$$

- Para a variância, temos:

$$\hat{Var}(X) = \frac{1}{M} \sum_{i=1}^M x_i^2 - \left( \frac{1}{M} \sum_{i=1}^M x_i \right)^2$$

# Convergência Pointwise

- **Definição:** Uma sequência  $\{X_n\}$  converge para um limite  $X$  se e somente se, para qualquer  $\epsilon > 0$  por menor que seja, podemos encontrar um inteiro  $n_o$  tal que

$$|X_n - X| < \epsilon$$

para todo  $n > n_o$ .

- Considere agora uma sequência de variáveis aleatórias

$$\{X_1, X_2, \dots, X_n, \dots\}$$

e a definição de convergência pointwise para outra variável  $X$ , então é necessário ter para todo  $\omega$ -ponto em  $\Omega$  a seguinte sequência

$$X_1(\omega), X_2(\omega), \dots, X_n(\omega)$$

convergindo para  $X(\omega)$ . Este tipo de convergência é chamada **everywhere convergence** - altamente restritiva. Devemos olhar para sub-conjuntos de  $\Omega$ .

# Convergência Almost Sure

- **Definição:** Uma sequência de variáveis aleatórias  $\{X_n\}$  converge *almost sure* (a.s.) para  $X$  se para cada  $\omega$ -ponto não pertencente ao evento nulo  $A$ ,

$$\lim_{n \rightarrow \infty} |X_n(\omega) - X(\omega)| = 0$$

- Este tipo de convergência é também conhecida como convergência com probabilidade 1 e possui a seguinte notação

$$X_n(\omega) \xrightarrow[n \rightarrow \infty]{a.s.} X(\omega) \text{ ou } X(\omega) = \lim_{n \rightarrow \infty} X_n(\omega) \text{ (a.s.)}$$

- Se o limite de  $X$  não é conhecido *a priori*, podemos definir a convergência *almost sure* mutual. A sequência  $X_n$  converge mutualmente *almost sure* se

$$\sup_{m \geq n} |X_m - X_n| \xrightarrow[n \rightarrow \infty]{a.s.} 0$$

# Convergência Almost Sure (cont.)

- Uma maneira alternativa de se testar a convergência quase certamente é olhar para

$$P(\{\omega : X_n(\omega) \rightarrow X(\omega)\}) = 1 \quad \text{quando} \quad n \rightarrow \infty$$

ou

$$\lim_{n \rightarrow \infty} P(\sup_{m \geq n} |X_m - X| > \epsilon) = 0 \quad \text{para todo} \quad \epsilon > 0$$

ou

$$\lim_{n \rightarrow \infty} P(\sup_{m \geq n} |X_m - X| \leq \epsilon) = 1 \quad \text{para todo} \quad \epsilon > 0$$

- A convergência quase certamente põe restrições no comportamento conjunto de todos elementos aleatórios na sequência  $|X_n - X|$ ,  $|X_{n+1} - X|$ , ...

# Convergência em Probabilidade

- **Definição:** A sequência de variáveis aleatórias  $\{X_n\}$  converge *em probabilidade* para  $X$  se para  $\epsilon > 0$  pequeno

$$\lim_{n \rightarrow \infty} P(|X_n - X| \geq \epsilon) = 0$$

ou

$$\lim_{n \rightarrow \infty} P(|X_n - X| < \epsilon) = 1$$

- A notação usada é a seguinte

$$X_n(\omega) \xrightarrow[n \rightarrow \infty]{l.i.p} X(\omega) \text{ ou } X(\omega) = \lim_{n \rightarrow \infty}^{l.i.p} X_n(\omega)$$

- A convergência em probabilidade mutual é definida como

$$\lim_{n \rightarrow \infty} \sup_{m \geq n} P(|X_m - X_n| \geq \epsilon) \rightarrow 0$$

# Convergência em Probabilidade (cont.)

- A convergência em probabilidade olha para a distribuição marginal de  $|X_n - X|$  quando  $n \rightarrow \infty$ .
- O conceito de convergência em probabilidade será uma importante ferramenta quando estudarmos a convergência de estimadores e a lei Fraca dos Grandes Números.
- Alguns resultados importantes:
  - Se a sequência de variáveis aleatórias  $\{X_n\}$  converge *almost sure* para  $X$ , então converge em probabilidade para o mesmo limite. O contrário não é verdadeiro.
  - Se  $\{X_n\}$  converge em probabilidade para  $X$ , então existe uma sub-sequência  $\{X_{n_k}\}$  de  $\{X_n\}$  que converge *almost sure* para o mesmo limite.
  - $\{X_n\}$  converge em probabilidade se e somente se converge mutualmente em probabilidade.



# Diferença entre a convergência quase certamente e em probabilidade

## Primeira maneira de olhar

- **Convergência em probabilidade** - A chance de ter algum ponto fora dos limites vai para zero quando o  $n \rightarrow \infty$ .
- **Convergência quase certamente** - É mais forte! O número de pontos fora do limite é finito (countável?). Ou seja, à medida que  $n$  aumenta, o número de pontos fora dos limites se esgota  $\rightarrow$  tudo funciona perfeitamente. Infelizmente não se sabe quando isso acontece.

Na prática não há diferença entre os dois modos de convergência.

## Segunda maneira de olhar

# Diferença entre a convergência quase certamente e em probabilidade (cont.)

- **Convergência em probabilidade** - A probabilidade da sequência de variáveis aleatórias alcançar o alvo decresce exponencialmente e aproxima de zero mas não é zero.
- **Convergência quase certamente** - Algo irá acontecer (o alvo será alcançado) mas não sabemos quando.

# Convergência na Média

- **Definição:** Uma sequência de variáveis aleatórias  $\{X_n\}$  converge na  $p$ -ésima média ( $p > 0$ ) para  $X$  se

$$\lim_{n \rightarrow \infty} E(|X_n - X|^p) \rightarrow 0$$

que também por ser escrito como

$$X_n(\omega) \xrightarrow[n \rightarrow \infty]{l.i.p.m} X(\omega) \text{ ou } X(\omega) = \underset{n \rightarrow \infty}{l.i.p.m} X_n(\omega)$$

- Podemos também definir a convergência na  $p$ -ésima média mutual

$$\lim_{n \rightarrow \infty} \sup_{m \geq n} E(|X_m - X_n|^p) \rightarrow 0$$

# Convergência na Média (cont.)

- Um conceito importante é a convergência na média quadrada no qual  $p = 2$

$$\lim_{n \rightarrow \infty} E(|X_n - X|)^2 \rightarrow 0$$

ou de maneira equivalente, no caso da convergência em média quadrada mutual

$$\lim_{n \rightarrow \infty} \sup_{m \geq n} E(|X_m - X_n|^2) \rightarrow 0$$

- A notação usada é

$$X_n(\omega) \xrightarrow[n \rightarrow \infty]{l.i.q.m} X(\omega) \text{ ou } X(\omega) = \lim_{n \rightarrow \infty}^{l.i.q.m} X_n(\omega)$$

- Mesmo a convergência sendo mais restritiva (forte) do que a convergência em probabilidade, não implica ou não é implicada pela convergência *almost sure*.

# Convergência na Média (cont.)

- Alguns resultados importantes são:
  - Se a sequência de variáveis aleatórias  $\{X_n\}$  converge na  $p$ -ésima média, então converge em probabilidade para o mesmo limite.
  - $\{X_n\}$  converge na  $p$ -ésima média se e somente se converge mutualmente na  $p$ -ésima média.

# Em probabilidade mas não quase certamente

**Exemplo:** Seja  $X \sim U[0, 1]$  e os intervalos binários  $I_1 = [0, 1]$ ,  $I_2 = [0, \frac{1}{2}]$ ,  $I_3 = [\frac{1}{2}, 1]$ ,  $I_4 = [0, \frac{1}{4}]$ ,  $\dots$ ,  $I_7 = [\frac{3}{4}, 1]$ ,  $I_8 = [0, \frac{1}{8}]$  e assim por diante tal que

$$I_{2^m+i} = \left[ \frac{i}{2^m}, \frac{i+1}{2^m} \right]$$

para  $m = 0, 1, 2, \dots$  e  $i = 0, 1, \dots, 2^m - 1$ . Logo, os  $2^m$  intervalos de tamanho  $2^{-m}$  cobrem o intervalo  $[0, 1]$ .

- Seja  $Y_n = 1$  se  $X \in I_n$  e  $Y_n = 0$ , caso contrário. A sequência  $Y_1, Y_2, \dots$  converge *em probabilidade* para  $Y = 0$  pois, para todo  $0 < \epsilon \leq 1$ ,  $P(|Y_n - 0| \geq \epsilon) = P(Y_n = 1) = P(X \in I_n) = \text{tamanho do intervalo } I_n \rightarrow 0$ , quando  $n \rightarrow \infty$ .

- $Y_n$  não converge quase certamente para zero pois qualquer  $X$  está somente em um dos  $2^n$  intervalos de tamanho  $2^{-n}$ . Ou seja, para todo  $\omega \in \Omega$ ,  $Y(\omega)$  assume o valor 1 para um número infinito de  $n$ 's e assume o valor 0 para um número infinito de  $n$ 's. Logo, para cada  $\omega \in \Omega$ ,  $Y(\omega)$  não converge.

# Quase certamente e em $p$ -média implica em probabilidade

a) Considere a variável aleatória  $X_n$  tal que  $P(X_n = 0) = 1 - \frac{1}{n}$  e  $P(X_n = n) = \frac{1}{n}$ . Neste exemplo pode-se ver que  $X_n \xrightarrow{P} 0$  pois

$$\begin{aligned} P(|X_n| > \epsilon) &= P(X_n = n) \\ &= \frac{1}{n} \\ &\rightarrow 0 \end{aligned}$$

Entretanto

$$E(X_n) = 1$$

e consequentemente  $X_n$  não converge em média para zero.



# Quase certamente e em $p$ -média implica em probabilidade (cont.)

b) Suponha o modelo para  $X_n$  do exemplo anterior mas com  $\omega$  colhido de uma distribuição uniforme em  $[0, 1]$ , ou seja

$$X_n(\omega) = \begin{cases} n, & \omega \in [0, \frac{1}{n}), \\ 0, & \omega \in [\frac{1}{n}, 1] \end{cases}$$

tal que  $P(X_n = 0) = 1 - \frac{1}{n}$  e  $P(X_n = n) = \frac{1}{n}$  como antes. Para mostrar convergência quase certamente vamos utilizar a seguinte expressão

$$\lim_{n \rightarrow \infty} P(\sup_{m \geq n} |X_m - X_n| \leq \epsilon) = 1 \quad \text{para todo } \epsilon > 0$$

# Quase certamente e em $p$ -média implica em probabilidade (cont.)

Temos o seguinte com o limite  $X = 0$

$$\begin{aligned}\lim_{n \rightarrow \infty} P(\sup_{m \geq n} |X_m - X_n| \leq \epsilon) &= \lim_{n \rightarrow \infty} P(\sup_{m \geq n} |X_m| \leq \epsilon) \\ &= \lim_{n \rightarrow \infty} P(|X_n| \leq \epsilon, |X_{n+1}| \leq \epsilon, \dots) \\ &\geq \lim_{n \rightarrow \infty} P(X_n = 0, X_{n+1} = 0, \dots) \\ &= \lim_{n \rightarrow \infty} P\left(\omega \geq \frac{1}{n}, \omega \geq \frac{1}{n+1}, \dots\right) \\ &= \lim_{n \rightarrow \infty} P\left(\omega \geq \frac{1}{n}\right) \\ &= \lim_{n \rightarrow \infty} \left(1 - \frac{1}{n}\right) \\ &= 1\end{aligned}$$

# Quase certamente e em $p$ -média implica em probabilidade (cont.)

portanto converge quase certamente.

c) Suponhamos que os elementos de  $X_n$  sejam independentes. Para todos os valores positivos inteiros de  $n$ , temos

# Quase certamente e em $p$ -média implica em probabilidade (cont.)

$$\begin{aligned}P(X_n = 0, X_{n+1} = 0, \dots) &= \prod_{m=n}^{\infty} \left(1 - \frac{1}{m}\right) \\&= \lim_{N \rightarrow \infty} \prod_{m=n}^N \left(1 - \frac{1}{m}\right) \\&= \lim_{N \rightarrow \infty} \prod_{m=n}^N \frac{m-1}{m} \\&= \lim_{N \rightarrow \infty} \frac{n-1}{n} \frac{n}{n+1} \cdots \frac{N-2}{N-1} \frac{N-1}{N} \\&= \lim_{N \rightarrow \infty} \frac{n-1}{N} \\&= 0\end{aligned}$$

# Quase certamente e em $p$ -média implica em probabilidade (cont.)

e portanto, para todo  $\epsilon > 0$

$$\lim_{n \rightarrow \infty} P(\sup_{m \geq n} |X_m| \leq \epsilon) = 0$$

que viola a condição, ou seja, a convergência quase certamente de  $X_n$  para zero falha, assim como a convergência na média. Assim mesmo temos a convergência em probabilidade.

# Convergência em Distribuição

Seja  $X_n$  uma sequência de variáveis aleatórias e seja  $X$  uma variável aleatória. Suponha que  $X_n$  tenha distribuição  $F_n$  e que  $X$  tenha distribuição  $F$ .  $X_n$  converge em distribuição para a variável  $X$  se

$$\lim_{n \rightarrow \infty} F_n(t) = F(t)$$

para cada valor de  $t$  onde  $F$  é contínua. Notação:  $X_n \xrightarrow{d} X$ .

**Exemplo:** Seja  $X_n = 1 + \frac{1}{n}$  uma variável aleatória constante. Podemos facilmente ver que a distribuição de  $X_n$  é

$$F_n(t) = \begin{cases} 0, & \text{se } t < 1 + \frac{1}{n} \\ 1, & \text{se } t \geq 1 + \frac{1}{n} \end{cases}$$

# Convergência em Distribuição (cont.)

Note que  $\lim_n F_n(t) = \tilde{F}(t)$  onde

$$\tilde{F}(t) = \begin{cases} 0, & \text{se } t \leq 1 \\ 1, & \text{se } t > 1 \end{cases}$$

que não é uma distribuição, pois não é contínua a direita. Podemos, entretanto, definir

$$F(t) = \begin{cases} 0, & \text{se } t < 1 \\ 1, & \text{se } t \geq 1 \end{cases}$$

que é uma distribuição para a variável  $X = 1$ . Logo  $X_n \xrightarrow{d} X$ , mesmo que  $F_n(1) \not\rightarrow F(1)$ .