

Introdução aos Processos Estocásticos - Estimadores

Eduardo M. A. M. Mendes

DELT - UFMG
Programa de Pós-Graduação em Engenharia Elétrica
Universidade Federal de Minas Gerais
emmendes@cpdee.ufmg.br

Problema: Amostras retiradas de uma distribuição conhecida onde os parâmetros que caracterizam a distribuição são desconhecidos.

- Em geral, a pdf de uma variável aleatória X é $f(x|\theta)$ onde θ é o vetor de parâmetros que caracterizam a pdf. O vetor de parâmetros θ é definido no espaço de parâmetros Θ .
- Para cada valor de $\theta \in \Theta$, existe uma pdf diferente.
- Para obter valores para o vetor de parâmetros, amostras aleatórias são retiradas da população e uma estatística denominada **estimador** é construída.
- Os valores dos estimadores são chamados **estimativas pontuais**.

Métodos baseados na Média Amostral

Sabemos que

$$\bar{X} = \frac{1}{N} \sum_{i=1}^N X_i \quad X \text{ é IID}$$

Podemos calcular o valor esperado

$$\begin{aligned} E(\bar{X}) &= E\left(\frac{1}{N} \sum_{i=1}^N X_i\right) \\ &= \frac{1}{N} \sum_{i=1}^N E(X_i) \\ &= \frac{1}{N} \sum_{i=1}^N E(X) \\ &= E(X) \end{aligned}$$

Métodos baseados na Média Amostral (cont.)

e a variância

$$\begin{aligned} \text{Var}(\bar{X}) &= \text{Var}\left(\frac{1}{N} \sum_{i=1}^N X_i\right) \\ &= \frac{1}{N^2} \sum_{i=1}^N \text{Var}(X) \\ &= \frac{\text{Var}(X)}{N} \end{aligned}$$

Propriedades dos Estimadores

Considere o experimento que produz os valores amostrais de uma variável aleatória X .

- Um número indefinido de VAs X_1, X_2, \dots , todas com o mesmo modelo probabilístico de X .
- Assuma que θ é parâmetro do modelo probabilístico.
- As observações X_1, X_2, \dots são usadas para produzir uma sequência de estimadores de θ . As estimativas $\hat{T}_1, \hat{T}_2, \dots$ são variáveis aleatórias.

$$\begin{array}{lll} T_1 & \text{depende de} & X_1 \\ T_2 & \text{depende de} & X_1 \text{ e } X_2 \\ \vdots & & \\ T_N & \text{depende de} & X_1 \quad \dots \quad X_N \end{array}$$

Estimador Consistente

Estimador Consistente: A sequência de estimativas $\hat{T}_1, \hat{T}_2, \dots$ do parâmetro θ é consistente se para qualquer $\epsilon > 0$

$$\lim_{N \rightarrow \infty} P \left[|\hat{T}_N - \theta| \geq \epsilon \right] = 0$$

Exemplo: Seja $\{X_1, X_2, \dots, X_N\}$ uma amostra aleatória de tamanho N de uma distribuição com média μ e variância σ^2 . Mostre que \bar{X}_N é um estimador consistente de μ .

Solução: Para que \bar{X}_N seja um estimador de μ , precisamos mostrar que

$$\lim_{N \rightarrow \infty} P \left[|\bar{X}_N - \mu| \geq \epsilon \right] = 0$$

Usando a inequação de Chebyshev e o fato de que $E(\bar{X}) = \mu$ e $Var(\bar{X}_N) = \frac{\sigma^2}{N}$, temos

$$P \left[|\bar{X}_N - \mu| \geq \epsilon \right] \leq \frac{\sigma^2}{N\epsilon^2}$$

Como $N \rightarrow \infty$ e σ^2 é finito, logo

$$\lim_{N \rightarrow \infty} P \left[|\bar{X}_N - \mu| \geq \epsilon \right] = 0$$

Estimador Não-Polarizado

Estimador Não-Polarizado: Uma estimativa, \hat{T} , do parâmetro θ é não polarizada se

$$E(\hat{T}) = \theta$$

Caso contrário é polarizada. Podemos, então, definir polarização (bias) como

$$bias = E(\hat{T}) - \theta$$

Exemplo: Suponha $X \sim Pois(\lambda)$ ($E(X) = Var(X) = \lambda$) onde λ é desconhecido. Mostrar que

(a) \bar{X} é um estimador não-polarizado de λ . Para mostrar isso, considere

$$E(\bar{X}) = E\left(\sum_{i=1}^N \frac{X_i}{N}\right) = \sum_{i=1}^N \frac{E(X_i)}{N} = \frac{N\lambda}{N} = \lambda$$

(b) $2\bar{X}$ é um estimador não-polarizado de 2λ .

$$E(2\bar{X}) = 2E(\bar{X}) = 2\lambda$$

(c) \bar{X}^2 é um estimador polarizado de λ^2 .

$$E(\bar{X}^2) = \text{Var}(\bar{X}) + \mu_{\bar{X}}^2 = \frac{\lambda}{N} + \lambda^2 \neq \lambda^2$$

Estimador Não-Polarizado assintoticamente

Estimador Não-Polarizado assintoticamente: A sequência de estimadores \hat{T}_N do parâmetro θ é assintoticamente não-polarizada se

$$\lim_{N \rightarrow \infty} E(\hat{T}_N) = \theta$$

Exemplo: No exemplo anterior temos

$$E(\bar{X}^2) = \text{Var}(\bar{X}) + \mu_{\bar{X}}^2 = \frac{\lambda}{N} + \lambda^2 \xrightarrow{N \rightarrow \infty} \lambda^2$$

Erro Quadrático Médio (MSE)

Erro Quadrático Médio (MSE): O erro quadrático médio do estimador \hat{T} é

$$e = E \left((\hat{T} - \theta)^2 \right)$$

- O MSE consiste de dois componentes não-negativos: a variância do estimador \hat{T} e a polarização (bias = $E(\hat{T}) - \theta$) ao quadrado do mesmo estimador:

$$\begin{aligned} MSE(\hat{T}) &= E \left((\hat{T} - E(\hat{T}) + E(\hat{T}) - \theta)^2 \right) \\ &= E \left((\hat{T} - E(\hat{T}))^2 \right) + E \left((E(\hat{T}) - \theta)^2 \right) + 2E \left((\hat{T} - E(\hat{T}))(E(\hat{T}) - \theta) \right) \\ &= Var(\hat{T}) + (E(\hat{T}) - \theta)^2 + 2 \left(E(\hat{T}) - E(\hat{T}) \right) (E(\hat{T}) - \theta) \\ &= Var(\hat{T}) + (E(\hat{T}) - \theta)^2 \\ &= Var(\hat{T}) + (bias(\hat{T}))^2 \end{aligned}$$

Erro Quadrático Médio (MSE) (cont.)

- Quando \hat{T} é uma estimativa não polarizada de θ e $E(\hat{T}) = \theta$, MSE é simplesmente a variância de \hat{T} .
- Para uma sequência de estimadores não polarizados, é suficiente mostrar que o MSE vai para zero para provar que o estimador é consistente.

Teorema: Se a sequência de estimativas não polarizadas $\hat{T}_1, \hat{T}_2, \dots$ do parâmetro θ tem MSE com

$$e_N = \text{Var}(\hat{T}_N)$$

satisfazendo $\lim_{N \rightarrow \infty} e_N = 0$, então a sequência é consistente.

Prova: Como $E(\hat{T}_N) = \theta$, a desigualdade de Chebyshev pode ser aplicada a \hat{T}_N . Para a constante $\epsilon > 0$

Erro Quadrático Médio (MSE) (cont.)

$$P\left(|\hat{T}_N - \theta| > \epsilon\right) \leq \frac{\text{var}(\hat{T}_N)}{\epsilon^2}$$

No limite

$$\lim_{N \rightarrow \infty} P\left(|\hat{T}_N - \theta| > \epsilon\right) \leq \lim_{N \rightarrow \infty} \frac{\text{var}(\hat{T}_N)}{\epsilon^2} = 0$$

Exemplo: Em um intervalo de k segundos, o número N_k de pacotes passando por um roteador é uma VA de Poisson com valor esperado $E[N_k] = k\theta$ pacotes. Seja $\hat{T}_k = \frac{N_k}{k}$ uma estimativa de θ . Cada estimativa \hat{T}_k é uma estimativa não polarizada de θ ? Qual é o MSE?

Erro Quadrático Médio (MSE) (cont.)

Solução:

$$E\left(\hat{T}_k\right) = E\left(\frac{N_k}{k}\right) = \frac{E(N_k)}{k} = \theta$$

Como N_k é Poisson, $Var(N_k) = k\theta$:

$$Var\left(\hat{T}_k\right) = Var\left(\frac{N_k}{k}\right) = \frac{Var(N_k)}{k^2} = \frac{\theta}{k}$$

Como \hat{T}_k é não polarizada

$$MSE = \frac{\theta}{k}$$

Repare que

$$\lim_{k \rightarrow \infty} Var\left(\hat{T}_k\right) = 0, \quad \text{então}$$

Erro Quadrático Médio (MSE) (cont.)

a sequência de estimadores \hat{T}_k é consistente.

Estimativa do Valor Esperado

Considerando que $\theta = E(X)$, o estimador usado é

$$\hat{T}_N = \bar{X} \quad (\text{Média Amostral})$$

- Como $E(\bar{X}) = E(X)$, a média amostral é não-polarizada.

$$e_N = E((\bar{X} - E(X))^2) = \text{Var}(\bar{X}) = \frac{\text{Var}(X)}{N}$$

Teorema: Se X tem variância finita, então a média amostral \bar{X} é uma sequência de estimadores consistentes de $E(X)$.

Prova

$$\lim_{N \rightarrow \infty} \text{Var}(\bar{X}) = \lim_{N \rightarrow \infty} \frac{\text{Var}(X)}{N} = 0$$

então \bar{X} é uma sequência consistente.

Considerando

$$\theta = \text{Var}(X) = E((X - \mu_X)^2)$$

temos que analisar dois casos: quando $E(X)$ é conhecido e quando $E(X)$ não é conhecido.

- Suponha que X tenha média zero, logo $\text{Var}(X) = E(X^2)$.

$$Y = X^2 \rightarrow E(Y)$$

↓

$$\bar{Y} = \frac{1}{N} (X_1^2 + X_2^2 + \dots + X_N^2)$$

Se $\text{Var}(Y)$ existe, pela Lei dos Grandes Números, implica que \bar{Y} é um estimador consistente de $E(X^2) = \text{Var}(X)$.

Estimativas da Variância (cont.)

- Quando $E(X)$ é conhecido, ou seja, $E(X) = \mu_X$, implica que $Var(X) = E((X - \mu_X)^2)$. Faz-se

$$W = (X - \mu_X)^2$$

e

$$\bar{W} = \frac{1}{N} \sum_{i=1}^N (X_i - \mu_X)^2$$

se $Var(W)$ existe, \bar{W} é um estimador não polarizado e consistente de $Var(X)$.

- Quando o valor esperado de X não é conhecido, a situação é mais complicada pois a variância de X depende de μ_X .

Estimativas da Variância (cont.)

- A variância amostral de um conjunto de N observações independentes da variável X é

$$V_N(X) = \frac{1}{N} \sum_{i=1}^N (X_i - \bar{X})^2$$

então $V_N(X)$ é um estimador polarizado de $\text{Var}(X)$.

Prova: Substituindo $\bar{X} = \frac{1}{N} \sum_{i=1}^N X_i$ em

$$V_N(X) = \frac{1}{N} \sum_{i=1}^N (X_i - \bar{X})^2$$

resulta

$$V_N = \frac{1}{N} \sum_{i=1}^N X_i^2 - \frac{1}{N^2} \sum_{i=1}^N \sum_{j=1}^N X_i X_j$$

Estimativas da Variância (cont.)

como X_i é IID, então

$$\begin{aligned}E(X_i^2) &= E(X^2), \quad \forall i \text{ e} \\E(X_i)E(X_j) &= \mu_X^2\end{aligned}$$

Sabe-se que

$$\begin{aligned}E(X_i X_j) &= \text{cov}(X_i, X_j) + E(X_i)E(X_j) \\&= \text{cov}(X_i, X_j) + \mu_X^2\end{aligned}$$

Logo

$$\begin{aligned}E(V_N) &= E(X^2) - \frac{1}{N^2} \sum_{i=1}^N \sum_{j=1}^N (\text{cov}(X_i, X_j) + \mu_X^2) \\&= \text{Var}(X) - \frac{1}{N^2} \sum_{i=1}^N \sum_{j=1}^N \text{cov}(X_i, X_j)\end{aligned}$$

Estimativas da Variância (cont.)

Como os dois únicos termos diferentes de zero no somatório são $cov(X_i, X_i) = Var(X_i)$

$$\begin{aligned} E(V_N) &= Var(X) - \frac{1}{N^2} (NVar(X)) \\ &= \frac{N-1}{N} Var(X) \end{aligned}$$

Embora $V_n(X)$ seja um estimador polarizado, ele é assintoticamente não polarizado pois

$$\lim_{N \rightarrow \infty} E(V_n(X)) = \lim_{N \rightarrow \infty} \frac{N-1}{N} Var(X) = Var(X)$$

Estimativas da Variância (cont.)

- **Teorema:** A estimativa

$$S^2 = V'_N(X) = \frac{1}{N-1} \sum_{i=1}^N (X_i - \bar{X})^2$$

é um estimador não polarizado.

Prova:

$$V'_N(X) = \frac{N}{N-1} V_N(X)$$

logo

$$E(V'_N) = \frac{N}{N-1} E(V_N(X)) = \text{Var}(X)$$

Estimativas da Variância (cont.)

Repare que se $N = 1$, temos

$$\bar{X} = X_1 \quad \text{e} \quad V_1(X) = 0$$
$$V_1'(X) = \text{indefinido}$$

- Além de ser não-polarizado, uma outra propriedade importante de um bom estimador é possuir uma variância pequena, ou seja, estimadores que apresentem *MSE* reduzido.
- Um meio de comparar os *MSEs* dos estimadores é calcular a **eficiência relativa**. Dados dois estimadores, \hat{T}_1 e \hat{T}_2 , a eficiência de \hat{T}_1 relativo a \hat{T}_2 é

$$eff(\hat{T}_1, \hat{T}_2) = \frac{MSE(\hat{T}_2)}{MSE(\hat{T}_1)}$$

- Caso o estimador seja não-polarizado, a eficiência de \hat{T}_1 relativo a \hat{T}_2 pode ser escrito como

$$eff(\hat{T}_1, \hat{T}_2) = \frac{Var(\hat{T}_2)}{Var(\hat{T}_1)}$$

- O estimador \hat{T}_1 é mais eficiente do que \hat{T}_2 , se $MSE(\hat{T}_1) < MSE(\hat{T}_2)$ ou

$$eff(\hat{T}_1, \hat{T}_2) > 1$$

- Se $T = \hat{\theta}$ é um estimador não-polarizado de θ e as amostras de tamanho N , X_1, X_2, \dots, X_N , têm PDF $f(x|\theta)$, então a variância do estimador não-polarizado $\hat{\theta}$ deve satisfazer a seguinte desigualdade

$$Var(\hat{\theta}) \geq \frac{1}{N \times E \left(\left(\frac{\partial \ln(f(X|\theta))}{\partial \theta} \right)^2 \right)}$$

onde $f(X|\theta)$ é a PDF de interesse tomada em X . A desigualdade acima é denominada **Desigualdade de Cramér-Rao**.

Eficiência (cont.)

- Se $\hat{\theta}$ é um estimador não-polarizado e

$$Var(\hat{\theta}) = \frac{1}{\underbrace{N \times E \left(\left(\frac{\partial \ln(f(X|\theta))}{\partial \theta} \right)^2 \right)}_{\text{Cramér-Rao Bound (CRLB)}}}$$

então $\hat{\theta}$ é um estimador **de variância mínima não-polarizado** de θ .

Exemplo: Mostre que \bar{X} é o estimador não-polarizado de mínima variância da média λ de população de Poisson.

Solução: Se $X \sim \text{Pois}(\lambda)$ com $E(X) = Var(X) = \lambda$ e PDF

$$p(X = x|\lambda) = \frac{\lambda^x e^{-\lambda}}{x!}$$

Eficiência (cont.)

Como

$$E(\bar{X}) = \sum_{i=1}^N \frac{X_i}{N} = \frac{N\lambda}{N} = \lambda$$

\bar{X} é um estimador não-polarizado de λ com variância $\frac{\lambda}{N}$, pois

$$\text{Var}(\bar{X}) = \text{Var}\left(\sum_{i=1}^N \frac{X_i}{N}\right) = \frac{1}{N^2} \sum_{i=1}^N \text{Var}(X_i) = \frac{N\lambda}{N^2} = \frac{\lambda}{N}$$

consequentemente, se o CRLB é $\frac{\lambda}{N}$, \bar{X} é o estimador não-polarizado de variância mínima de λ . Para mostrar isso, considere

$$\ln(p(x|\lambda)) = x\ln(\lambda) - \lambda - \ln(x!)$$

Calculando a derivada da função acima em relação a λ resulta em

$$\frac{\partial p(x|\lambda)}{\partial \lambda} = \frac{x}{\lambda} - 1 = \frac{x - \lambda}{\lambda}$$

Logo

$$\begin{aligned} E \left(\left(\frac{\partial p(X|\lambda)}{\partial \lambda} \right)^2 \right) &= E \left(\left(\frac{X - \lambda}{\lambda} \right)^2 \right) \\ &= \frac{E((X - \lambda)^2)}{\lambda^2} \\ &= \frac{\text{Var}(X)}{\lambda^2} \\ &= \frac{\lambda}{\lambda^2} = \frac{1}{\lambda} \end{aligned}$$

Finalmente o CRLB é

$$\frac{1}{N \times E \left(\left(\frac{\partial \ln(f(X|\theta))}{\partial \theta} \right)^2 \right)} = \frac{\lambda}{N}$$

Consequentemente, como \bar{X} é não-polarizado e $Var(\bar{X}) = \frac{\lambda}{N}$, o estimador é de mínima variância.

- A essência de um estimador robusto é um estimador cuja distribuição amostral não é seriamente afetada pelas violações das suposições feitas ao solucionar o problema de estimação.
- O conceito de robustez também é usado para se referir a habilidade de um estimador em particular de proporcionar estimativas razoáveis quando observações atípicas são encontradas na amostra.

Exemplo: A mediana é um estimador robusto do centro de uma distribuição assimétrica.

Técnicas de Estimação

Vamos considerar dois métodos clássicos:

- 1) Método dos Momentos
- 2) Método da Verossimilhança

Lembrando a notação usada

- A informação nas variáveis aleatórias $X_1, X_2, X_3, \dots, X_N$ é usada para fazer inferências sobre o parâmetro não-conhecido θ .
- Os valores observados da variável aleatória são $x_1, x_2, x_3, \dots, x_N$.
- a PDF conjunta é dada por

$$\begin{aligned} f(\mathbf{x}|\theta) &= f(x_1, x_2, x_3, \dots, x_n|\theta) \\ &= f(x_1|\theta) \times f(x_2|\theta) \times \dots \times f(x_N|\theta) \\ &= \prod_{i=1}^N f(x_i|\theta) \end{aligned}$$

Métodos dos Momentos

Idéia: Igualar os momentos com os momentos amostrais correspondentes. O r -ésimo Momento Amostral, m_r , é definido como

$$m_r = \frac{1}{N} \sum_{i=1}^N X_i^r$$

O momento de uma variável aleatória foi definido como

$$\alpha_r = E(X^r) = \sum_{i=1}^{\infty} x_i^r p(X = x_i) \text{ ou } \int_{-\infty}^{\infty} x^r f(x) dx$$

Dada uma amostra aleatória X_1, X_2, \dots, X_N de uma população com PDF $f(x|\theta_1, \theta_2, \dots, \theta_k)$, no métodos dos momentos, os estimadores θ_i para $i = 1, \dots, k$ são determinados igualando os primeiros k momentos com os momentos amostrais correspondentes e resolvendo o sistema resultante.

$$\begin{cases} \alpha_1(\theta_1, \dots, \theta_k) = m_1 \\ \alpha_2(\theta_1, \dots, \theta_k) = m_2 \\ \vdots \\ \alpha_k(\theta_1, \dots, \theta_k) = m_k \end{cases}$$

Considerações sobre o método:

- Fácil utilização e obtenção de estimadores consistentes.
- Sob certas condições, os momentos amostrais convergem para os momentos da população.
- Os momentos amostrais são estimadores não-polarizados.

Métodos dos Momentos (cont.)

Exemplo: Dada uma amostra de tamanho N da distribuição $Gamma(\alpha, \lambda)$, encontrar, pelo método dos momentos, estimadores de α e λ .

Solução: Sabemos que para a distribuição $Gamma(\alpha, \lambda)$

$$\begin{aligned}E(X) &= \frac{\alpha}{\lambda} \\Var(X) &= \frac{\alpha}{\lambda^2}\end{aligned}$$

e que o primeiro e segundo momentos amostrais são

$$\begin{aligned}m_1 &= \bar{X} \\m_2 &= \frac{1}{N} \sum_{i=1}^N x_i^2\end{aligned}$$

Métodos dos Momentos (cont.)

Calculando o primeiro e segundo momentos da população, temos:

$$\alpha_1(\alpha, \lambda) = E(X^1) = \frac{\alpha}{\lambda}$$

$$\alpha_2(\alpha, \lambda) = E(X^2) = \sigma^2 + E(X)^2 = \frac{\alpha}{\lambda^2} + \frac{\alpha^2}{\lambda^2} = \frac{\alpha(1 + \alpha)}{\lambda^2}$$

Montando o sistema de equações, temos

$$\begin{cases} \alpha_1(\alpha, \lambda) = \frac{\alpha}{\lambda} = \bar{X} = m_1 \\ \alpha_2(\alpha, \lambda) = \frac{\alpha(1+\alpha)}{\lambda^2} = \frac{1}{N} \sum_{i=1}^N x_i^2 = m_2 \end{cases}$$

Chamando $S^2 = \frac{\sum_{i=1}^N (x_i - \bar{X})^2}{N}$, podemos chegar a seguinte solução do sistema acima

Métodos dos Momentos (cont.)

$$\hat{\alpha} = \frac{\bar{X}^2}{S^2}$$
$$\hat{\lambda} = \frac{\bar{X}}{S^2}$$

Idéia: Selecionar o valor de θ que faça com que o modelo probabilístico, $f(x|\theta)$, seja o mais “provável” gerador dos dados observados.

- $L(\theta|\mathbf{x})$ é a função de verossimilhança de θ para X

$$L(\theta|\mathbf{x}) = f(\mathbf{x}|\theta) = \prod_{i=1}^N f(x_i|\theta) = f(x_1|\theta) \times \cdots \times f(x_n|\theta)$$

- O valor de θ que maximiza $L(\theta|\mathbf{x})$ é chamado estimativa de máxima verossimilhança (MLE).

Estimadores de Máxima Verossimilhança (cont.)

- Devido à dificuldade de manipulação de $L(\theta|\mathbf{x})$, opta-se pela chamada função log de verossimilhança, ou seja, $\ln(L(\theta|\mathbf{x}))$. Para achar θ , basta

$$\frac{\partial(\ln(L(\theta|\mathbf{x})))}{\partial\theta} = 0$$

Para achar um máximo, seja local ou global, é necessário calcular a derivada segunda

$$\left. \frac{\partial^2(\ln(L(\theta|\mathbf{x})))}{\partial\theta^2} \right|_{\theta=\hat{\theta}(\mathbf{x})} < 0$$

Obs.: É necessário também testar as condições de contorno.

Estimadores de Máxima Verossimilhança (cont.)

Exemplo: Dada uma amostra aleatória de tamanho N de uma distribuição de Bernoulli, $Ber(p)$, determine a estimativa de verossimilhança e a de máxima verossimilhança do parâmetro p .

Solução: Sabemos que

$$P(X = x|p) = p^x(1 - p)^{1-x}$$

onde x é 1 com probabilidade p e 0 com probabilidade $(1 - p)$.

A função de verossimilhança para os N valores observados é

$$L(p|\mathbf{x}) = \prod_{i=1}^N p^{x_i}(1 - p)^{1-x_i}$$

Estimadores de Máxima Verossimilhança (cont.)

e

$$\begin{aligned}\ln(L(p|\mathbf{x})) &= \ln \left[\prod_{i=1}^N p^{x_i} (1-p)^{1-x_i} \right] \\ &= \sum_{i=1}^N \ln [p^{x_i} (1-p)^{1-x_i}] \\ &= \sum_{i=1}^N [x_i \ln(p) + (1-x_i) \ln(1-p)]\end{aligned}$$

Para achar o valor que maximiza a expressão acima, é necessário calcular a derivada parcial de primeira ordem de $\ln(L(p|\mathbf{x}))$ e igualar a zero

$$\frac{\partial \ln(L(p|\mathbf{x}))}{\partial p} = \frac{\sum_{i=1}^N x_i}{p} - \frac{N - \sum_{i=1}^N x_i}{1-p} = 0$$

Estimadores de Máxima Verossimilhança (cont.)

A solução é

$$p = \frac{\sum_{i=1}^N x_i}{N} = \bar{x}$$

Para que $p = \bar{x}$ seja máximo, é necessário que a derivada parcial de segunda ordem seja negativa no valor

$$\frac{\partial^2 \ln(L(p|\mathbf{x}))}{\partial p^2} = \frac{-\sum_{i=1}^N x_i}{p^2} - \frac{N - \sum_{i=1}^N x_i}{(1-p)^2} \bigg|_{p=\bar{x}} = -\frac{N}{\bar{x}} - \frac{N}{1-\bar{x}}$$

que é negativa para $0 \leq \bar{x} \leq 1$ e $N > 0$. Como, para $p = 0$ e $p = 1$, a função de verossimilhança é zero $p = \bar{x}$ é o valor que maximiza tal função.

Estimadores de Máxima Verossimilhança (cont.)

Exemplo: Suponha $\{X_1, X_2, \dots, X_N\}$ é uma amostra aleatória de uma distribuição gaussiana com $N(\mu, \sigma)$, onde σ é conhecido. Encontre o estimador de verossimilhança de μ .

Solução: A PDF de uma variável aleatória $X \sim N(\mu, \sigma)$ é

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}, \quad -\infty < x < \infty$$

A função de verossimilhança é

$$L(\mu|\mathbf{x}) = \prod_{i=1}^N f(x_i) = \prod_{i=1}^N \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x_i-\mu)^2}{2\sigma^2}}$$

Estimadores de Máxima Verossimilhança (cont.)

e o log dela

$$\ln(L(\mu|\mathbf{x})) = -\frac{N}{2}\ln(2\pi) - \frac{N}{2}\ln(\sigma^2) - \frac{\sum_{i=1}^N (x_i - \mu)^2}{2\sigma^2}$$

Para achar o valor que maximiza a função acima é preciso calcular a primeira derivada parcial e a segunda

$$\begin{aligned}\frac{\partial \ln(L(\mu|\mathbf{x}))}{\partial \mu} &= \frac{\sum_{i=1}^N (x_i - \mu)}{\sigma^2} = 0 \\ \frac{\partial^2 \ln(L(\mu|\mathbf{x}))}{\partial \mu^2} &= -\frac{N}{\sigma^2} < 0\end{aligned}$$

Como a função de verossimilhança vai para zero quando $x \rightarrow \pm\infty$, $\mu = \bar{x}$ é o máximo global.

- O objetivo é achar alguma medida sobre a variância dos estimadores encontrados.
- A informação de Fisher é uma dessas medidas.
- A informação de Fisher é a quantidade de informação que uma variável aleatória X carrega sobre um parâmetro θ desconhecido, do qual depende a função de verossimilhança $L(\theta|\mathbf{x})$ de X :

$$E \left[\left(\frac{\partial \ln(f(\mathbf{X}|\theta))}{\partial \theta} \right)^2 \right]$$

repare que a expressão acima é parte do denominador do CRLB.

- O inverso da informação de Fisher nos dá um limite para a variância do melhor estimador não-polarizado. Podemos então determinar duas formas para expressar o valor de informação para uma variável aleatória de tamanho N

$$I_N(\theta) = E \left[\left(\frac{\partial \ln(f(\mathbf{X}|\theta))}{\partial \theta} \right)^2 \right] = NI_N(\theta) = NE \left[\left(\frac{\partial \ln(f(X|\theta))}{\partial \theta} \right)^2 \right]$$

$$I_N(\theta) = -E \left[\left(\frac{\partial^2 \ln(f(\mathbf{X}|\theta))}{\partial \theta^2} \right) \right] = NI_N(\theta) = -NE \left[\left(\frac{\partial^2 \ln(f(X|\theta))}{\partial \theta^2} \right) \right]$$

Informação de Fisher (cont.)

Exemplo: Dada a PDF de uma distribuição gaussiana com média μ desconhecida e variância σ^2 conhecida, encontre a informação de Fisher de μ , dada uma amostra aleatória de tamanho N .

Solução: Já sabemos que a função de verossimilhança é

$$L(\mu|\mathbf{x}) = \prod_{i=1}^N f(x_i) = \prod_{i=1}^N \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x_i - \mu)^2}{2\sigma^2}}$$

e o log dela

$$\ln(L(\mu|\mathbf{x})) = -\frac{N}{2} \ln(2\pi) - \frac{N}{2} \ln(\sigma^2) - \frac{\sum_{i=1}^N (x_i - \mu)^2}{2\sigma^2}$$

Note que

$$\frac{\partial \ln(f(x|\mu))}{\partial \mu} = \frac{(x - \mu)}{\sigma^2}$$
$$\frac{\partial^2 \ln(f(x|\mu^2))}{\partial \mu} = -\frac{1}{\sigma^2}$$

Usando as expressões anteriores, podemos escrever

$$\begin{aligned}I_N(\mu) &= NE \left[\left(\frac{\partial \ln(f(X|\mu))}{\partial \mu} \right)^2 \right] \\&= NE \left[\left(\frac{X - \mu}{\sigma^2} \right)^2 \right] \\&= N \frac{E[(X - \mu)^2]}{\sigma^4} = \frac{N\sigma^2}{\sigma^4} = \frac{N}{\sigma^2}\end{aligned}$$

$$\begin{aligned}I_N(\mu) &= -NE \left[\left(\frac{\partial^2 \ln(f(X|\mu))}{\partial \mu^2} \right) \right] \\&= -NE \left[-\frac{1}{\sigma^2} \right] = \frac{N}{\sigma^2}\end{aligned}$$

Podemos notar que quanto menor é a variância, mais informação há na variável aleatória de tamanho N sobre o parâmetro μ .