

Introdução aos Processos Estocásticos - Sistemas Lineares

Eduardo M. A. M. Mendes

DELT - UFMG
Programa de Pós-Graduação em Engenharia Elétrica
Universidade Federal de Minas Gerais
emmendes@cpdee.ufmg.br

Consideraremos apenas Sistemas Lineares Discretos Invariantes no Tempo (LIT)




Figura 1: Sistema Linear

- Entrada \rightarrow PA WSS $U[n]$.
- Saída $\rightarrow X[n]$.

Introdução (cont.)

Exemplo: Processo MA

$$X[n] = \frac{1}{2} (U[n] + U[n-1])$$

onde $U[n]$ tem média e $r_U[k] = \sigma^2 \delta[k]$ – ruído branco não necessariamente precisa ser gaussiano.

Neste caso o processo MA pode ser visto como a saída do filtro linear com resposta ao impulso dada por

$$\begin{aligned} h[k] &= \frac{1}{2}, k = 0 \\ &= \frac{1}{2}, k = 1 \\ &= 0, \text{ caso contrário} \end{aligned}$$

Para sistemas LIT

Introdução (cont.)

1) Convolução

$$\begin{aligned}x[n] &= \sum_{k=-\infty}^{\infty} h[k]u[n-k] = h[n] * u[n] \\&= h[0]U[n] + h[1]U[n-1] \\&= \frac{1}{2}U[n] + \frac{1}{2}U[n-1]\end{aligned}$$

2) Transformada \mathcal{Z}

$$\begin{aligned}H(z) &= \sum_{k=-\infty}^{\infty} h[k]z^{-k} \\&= \frac{1}{2}z^0 + \frac{1}{2}z^{-1} \\&= \frac{1}{2} + \frac{1}{2}z^{-1}\end{aligned}$$

3) Resposta em Frequência - Fourier ($|f| \leq \frac{1}{2}$).

$$\begin{aligned} H(f) &= \sum_{k=-\infty}^{\infty} h[k]e^{-j2\pi fk} \\ &= \frac{1}{2}e^{-j2\pi f(0)} + \frac{1}{2}e^{-j2\pi f(1)} \\ &= \frac{1}{2} + \frac{1}{2}e^{-j2\pi f} \end{aligned}$$

ou

$$H(f) = H(z)|_{z=e^{j2\pi f}}$$

Sabemos que, dada uma entrada $e^{-j2\pi f_0 n}$, a saída será

$$H(f_0)e^{-j2\pi f_0 n}$$

Introdução (cont.)

onde

$$|H(f_0)| = \text{Magnitude, } f = f_0$$

$$\angle H(f_0) = \text{Fase, } f = f_0$$

Exemplo:




Figura 2: Sistema Linear

Neste caso:

- $U[n]$ - WSS, μ_u , $r_U[k]$.
- $H(z) = h[0] + h[1]z^{-1}$.
- $X[n] = h[0]U[n] + h[1]U[n - 1]$

Introdução (cont.)

Aplicando a esperança matemática em $X[n]$, temos

$$\begin{aligned} E[X[n]] &= h[0] \underbrace{E[U[n]]}_{=\mu_U} + h[1] \underbrace{E[U[n-1]]}_{=\mu_U} \\ &= (h[0] + h[1]) \mu_U \text{ Não depende de } n! \end{aligned}$$

$$\mu_X = \frac{(h[0] + h[1])}{\sum_{k=-\infty}^{\infty} h[k]z^{-k}|_{z=1}} \mu_U$$

Em geral

$$\mu_X = \left(\sum_{k=-\infty}^{\infty} h[k]z^{-k} \Big|_{z=1} \right) \mu_U = H(0)\mu_U$$

Para $E[X[n]X[n+k]]$

Introdução (cont.)

$$\begin{aligned} E[X[n]X[n+k]] &= E[(h[0]U[n] + h[1]U[n-1]) \times (h[0]U[n+k] + h[1]U[n+k-1])] \\ &= (h^2[0] + h^2[1])r_U[k] + h[0]h[1]r_U[k-1] + h[1]h[0]r_U[k+1] \\ &= r_X[k] \end{aligned}$$

como não depende de n

$$X[n] \implies \text{WSS}$$

Note que

$$\begin{aligned} g[0] &= h^2[0] + h^2[1] \\ g[1] &= h[0]h[1] \\ g[-1] &= h[1]h[0] \end{aligned}$$

Logo

$$\begin{aligned} r_X[k] &= g[0]r_U[k] + g[1]r_U[k-1] + g[-1]r_U[k+1] \\ &= \sum_{j=-1}^1 \underbrace{g[j]}_{=h[j]*h[-j]} r_U[k-j] \end{aligned}$$

Em relação à PSD, temos

$$\begin{aligned} P_X(f) &= \mathcal{F}(r_X[k]) \\ &= \mathcal{F}(g[k] * r_U[k]) \\ &= G(f) \times P_U f \end{aligned}$$

Introdução (cont.)

Se considerarmos

$$\begin{aligned}\mathcal{F}(h[k]) &= H(f) \\ \mathcal{F}(h[-k]) &= H^*(f)\end{aligned}$$

podemos escrever

$$\begin{aligned}P_X(f) &= G(f) \times P_U(f) \\ &= \mathcal{F}(h[k]) \times \mathcal{F}(h[-k]) \times P_U(f) \\ &= H(f) \times H^*(f) \times P_U(f) \\ &= |H(f)|^2 \times P_U(f)\end{aligned}$$

ou seja

- Entrada - $U[n]$ - WSS, μ_U , $P_U(f)$
- Saída - $X[n]$ - WSS, $\mu_X = H(0)\mu_U$, $P_X(f) = |H(f)|^2 \times P_U(f)$.

Introdução (cont.)

Caso Especial - Entrada Ruído Branco

$$P_U(f) = \sigma_U^2$$

Logo

$$\begin{aligned} P_X(f) &= |H(f)|^2 \times P_U(f) \\ &= |H(f)|^2 \sigma_U^2 \end{aligned}$$

O filtro **colore** o ruído \rightarrow correlaciona o ruído.

Exemplo: PA Autoregressivo (AR)

$$X[n] = aX[n-1] + \underbrace{U[n]}_{\text{ruído branco}}$$

Introdução (cont.)

A resposta em frequência é dada por

$$H(f) = H(z)|_{z=e^{j2\pi f}}$$

onde

$$H(z) = \frac{X(z)}{U(z)}$$




Figura 3: Sistema Linear

Introdução (cont.)

Determinando a função de transferência $H(z)$, temos

$$\begin{array}{ccc} x[n] & = & ax[n-1] + u[n] \\ \downarrow & & \downarrow \\ X(z) & = & az^{-1}X(z) + U(z) \end{array}$$

e

$$\begin{array}{ccc} H(z) & = & \frac{1}{1 - az^{-1}} \\ \downarrow & & \downarrow \\ H(f) & = & \frac{1}{1 - ae^{-j2\pi f}} \end{array}$$

e a PSD

$$\begin{aligned} P_X(f) &= |H(f)|^2 \times P_U(f) \\ &= \frac{1}{|1 - ae^{-j2\pi f}|^2} \sigma_U^2 \text{ com } |f| \leq \frac{1}{2} \end{aligned}$$

Para achar a ACS

Considere novamente a PSD

$$\begin{aligned}P_X(f) &= H(f) \times H^*(f) \times P_U(f) \\&= H(f) \times H^*(f) \times \sigma_U^2 \\&\downarrow \\r_X[k] &= (h[k] * h[-k]) \sigma_U^2 \\&= \sum_{i=-\infty}^{\infty} h[-i] \times h[k-i] \times \sigma_U^2 \\&\text{ou} \\&= \sigma_U^2 \underbrace{\sum_{m=-\infty}^{\infty} h[m] h[m+k]}_{\text{correlação}}\end{aligned}$$

Para achar a ACS (cont.)

Para sistemas causais

$$\begin{aligned} r_X[k] &= \sigma_U^2 \sum_{m=0}^{\infty} h[m]h[m+k] \text{ para } k \geq 0 \\ &= r_X[-k] \text{ para } k < 0 \end{aligned}$$

Exemplo: Considere o seguinte sistema linear

$$X[n] = \sum_{l=0}^{\infty} a^l U[n-l]$$

ou

$$X[n] = aX[n-1] + U[n] \text{ com } X[-1] = 0$$

determinar $r_X[k]$.

Para achar a ACS (cont.)

Solução: Considerando uma entrada impulsiva, podemos escrever

$$x[n] = h[n] = a^n \quad n \geq 0$$

logo

$$\left. \begin{aligned} h[l] &= a^l, \quad l \geq 0 \\ &= 0, \quad l < 0 \end{aligned} \right\} = a^l \underbrace{u_s[l]}_{\text{função degrau}}$$

e

$$r_X[k] = \sigma_U^2 \sum_{m=0}^{\infty} a^m u_s[m] a^{m+k} u_s[m+k]$$

Para $k \geq 0$ e $m \geq 0$, $u_s[m] = u_s[m+k] = 1$,

Para achar a ACS (cont.)

$$r_X[k] = \sigma_U^2 \sum_{m=0}^{\infty} a^{2m+k}$$

$$= \sigma_U^2 a^k \sum_{m=0}^{\infty} (a^2)^m$$

$$= \sigma_U^2 a^k \frac{1}{1-a^2} \text{ para } |a| < 1 \text{ e } k \geq 0$$

ou

$$= \sigma_U^2 a^{|k|} \frac{1}{1-a^2} \text{ com } -\infty < k < \infty$$

A idéia é trabalhar com a seguinte expressão

$$\int_{f_1}^{f_2} P_X(f) df = \text{Potência Média no intervalo } [f_1, f_2]$$

- Medição de Potência Média

Considere o sistema linear mostrado na figura abaixo




Figura 4: Sistema Linear

Interpretação da PSD (cont.)

com resposta em frequência




Figura 5: Resposta em Frequência

Potência Média na saída do filtro = $E[Y^2[n]] = r_Y[0]$. Mas

$$r_Y[k] = \int_{-\frac{1}{2}}^{\frac{1}{2}} P_Y(f) e^{j2\pi f k} df$$

e

$$\begin{aligned} r_Y[0] &= \int_{-\frac{1}{2}}^{\frac{1}{2}} P_Y(f) df \\ &\downarrow \\ E[y^2[n]] &= \int_{-\frac{1}{2}}^{\frac{1}{2}} P_Y(f) df \\ &= \int_{-\frac{1}{2}}^{\frac{1}{2}} |H(f)|^2 P_X(f) df \\ &= \int_{-f_0 - \frac{\Delta f}{2}}^{-f_0 + \frac{\Delta f}{2}} 1 \times P_X(f) df + \int_{f_0 - \frac{\Delta f}{2}}^{f_0 + \frac{\Delta f}{2}} 1 \times P_X(f) df \\ &= 2 \int_{f_0 - \frac{\Delta f}{2}}^{f_0 + \frac{\Delta f}{2}} P_X(f) df \end{aligned}$$

- Para $\Delta f \rightarrow 0$

$$\begin{aligned} r_Y[0] &= 2 \int_{f_0 - \frac{\Delta f}{2}}^{f_0 + \frac{\Delta f}{2}} P_X(f) df \\ &\approx 2P_X(f_0) \int_{f_0 - \frac{\Delta f}{2}}^{f_0 + \frac{\Delta f}{2}} df \\ &= 2P_X(f_0)\Delta f \end{aligned}$$

logo

$$\begin{aligned} P_X(f_0) &= \frac{1}{2} \frac{r_Y[0]}{\Delta f} \\ &= \frac{1}{2} \frac{\text{Potência Média Total na saída}}{\Delta f} \\ &= \frac{1}{2} \frac{2 \times \text{Potência Média total em } [f_0 - \frac{\Delta f}{2}, f_0 + \frac{\Delta f}{2}]}{\Delta f} \\ &= \frac{\text{Potência Média total em } [f_0 - \frac{\Delta f}{2}, f_0 + \frac{\Delta f}{2}]}{\Delta f} \\ &= \text{Potência por unidade de frequência} \\ &= \text{Densidade Espectral de Potência} \end{aligned}$$

Filtragem de Wiener




Figura 6: Filtragem e Suavização

Filtragem de Wiener (cont.)




Figura 7: Predição e Interpolação

Suavizador:

$$x[n] = s[n] + w[n] \text{ com } -\infty < n < \infty$$

Vamos supor que:

Filtragem de Wiener (cont.)

- $s[n]$ é um PA WSS com média zero e PSD $P_s(f)$.
- $w[n]$ é um PA WSS com média zero e PSD $P_w(f)$.

Objetivo: Estimar $s[n]$ para algum n_0 usando um filtro linear

$$\hat{s}[n_0] = \sum_{k=-\infty}^{\infty} \underbrace{h[k]}_{\text{n\~ao-causal}} x[n_0 - k]$$

que é o **Suavizador de Wiener**.

Problema: Determinar $h[k]$ que minimize o MSE, ou seja

$$MSE = E \left[(s[n_0] - \hat{s}[n_0])^2 \right]$$

Filtragem de Wiener (cont.)

No problema de regressão, sabemos que os resíduos, ξ , não são correlacionados com os regressores. Lembrando da estimação utilizando o método dos mínimos quadrados, temos

$$\underbrace{X}_{\text{Matriz de Regressores}} \theta = Y$$

$$\theta = (X^T X)^{-1} X^T Y$$

$$\xi = Y - X\theta$$

e

$$X^T \xi = 0 - \text{Princípio da Ortogonalidade}$$

No nosso caso

Filtragem de Wiener (cont.)

$$E \left[\left(s[n_0] - \sum_{k=-\infty}^{\infty} h[k] x[n_0 - k] \right) \times x[n_0 - l] \right] = 0 \text{ com } -\infty < l < \infty$$

logo

$$E [s[n_0] \times x[n_0 - l]] = \sum_{k=-\infty}^{\infty} h[k] E [x[n_0 - k] \times x[n_0 - l]]$$

Para distinguir os efeitos de $s[n]$ e $w[n]$ (lembre-se da definição de $x[n]$) é preciso, geralmente, que eles sejam não-correlacionados, ou seja, vamos assumir que

$$E [s[n] w[m]] = 0 \quad \forall m, n$$

Temos então

Filtragem de Wiener (cont.)

- $$\begin{aligned} E[s[n_0] \times x[n_0 - l]] &= E[s[n_0] (s[n_0 - l] + w[n_0 - l])] \\ &= E[s[n_0]s[n_0 - l]] \text{ (Princípio de Ortogonalidade)} \\ &= r_s[l] \end{aligned}$$

- $$\begin{aligned} E[x[n_0 - k]x[n_0 - l]] &= E[(s[n_0 - k] + w[n_0 - k]) \times (s[n_0 - l] + w[n_0 - l])] \\ &= E[s[n_0 - k]s[n_0 - l]] + E[w[n_0 - k]w[n_0 - l]] \\ &= r_s[l - k] + r_w[l - k] \end{aligned}$$

Logo

$$\begin{aligned}r_s[l] &= \sum_{k=-\infty}^{\infty} h[k] (r_s[l-k] + r_w[l-k]) \\&= \sum_{k=-\infty}^{\infty} h[k] r_s[l-k] + \sum_{k=-\infty}^{\infty} h[k] r_w[l-k] \\&= h[l] * r_s[l] + h[l] * r_w[l]\end{aligned}$$

- Achando a Transformada de Fourier

$$P_s(f) = H(f)P_s(f) + H(f)P_w(f)$$

e

$$H(f) = \frac{P_s(f)}{P_s(f) + P_w(f)}$$

Exemplo

Sinal AR em ruído com

$$P_s(f) = \frac{\sigma_U^2}{|1 - ae^{-j2\pi f}|^2}$$

e

$$P_w(f) = \sigma_w^2$$

Portanto o suavizador de Wiener é

$$H_{\text{ótimo}} = \frac{\frac{\sigma_U^2}{|1 - ae^{-j2\pi f}|^2}}{\frac{\sigma_U^2}{|1 - ae^{-j2\pi f}|^2} + \sigma_w^2}$$

Implementação do Filtro usando a IFFT

$$\hat{s}[n] = \int_{-\frac{1}{2}}^{\frac{1}{2}} \frac{P_s(f)}{P_s(f) + \sigma_w^2} \times \underbrace{X_N(f)}_{\text{Fourier - } \sum_{n=0}^{N-1} x[n]e^{-j2\pi fn}} e^{j2\pi fn} df$$

Exemplo (cont.)

Olhando para o MSE

$$\begin{aligned}MSE &= E \left[(s[n_0] - \hat{s}[n_0])^2 \right] \\&= E \left[(s[n_0] - \hat{s}[n_0]) s[n_0] \right] - \underbrace{E \left[\underbrace{(s[n_0] - \hat{s}[n_0])}_{\text{erro}} \hat{s}[n_0] \right]}_{\text{n\~ao-correlacionado} = 0} \\&= E \left[(s[n_0] - \hat{s}[n_0]) s[n_0] \right] \\&= E \left[(s[n_0])^2 \right] - E \left[\hat{s}[n_0] s[n_0] \right] \\&= r_s[0] - E \left[\sum_{k=-\infty}^{\infty} h_{\text{ótimo}}[k] x[n_0 - k] s[n_0] \right] \\&= r_s[0] - E \left[\sum_{k=-\infty}^{\infty} h_{\text{ótimo}}[k] (s[n_0 - k] + w[n_0 - k]) s[n_0] \right]\end{aligned}$$

Exemplo (cont.)

mas $w[n_0 - k]$ e $s[n_0]$ não são correlacionados. Finalmente

$$\begin{aligned} MSE &= r_s[0] - \sum_{k=-\infty}^{\infty} h_{\text{ótimo}}[k] \underbrace{E[s[n_0 - k]s[n_0]]}_{=r_s[k]} \\ &= r_s[0] - \sum_{k=-\infty}^{\infty} h_{\text{ótimo}}[k] r_s[k] \end{aligned}$$

Passando para o domínio da frequência e usando Parseval

Exemplo (cont.)

$$\begin{aligned}MSE &= \int_{-\frac{1}{2}}^{\frac{1}{2}} P_s(f) df - \int_{-\frac{1}{2}}^{\frac{1}{2}} H_{\text{ótimo}} P_s(f) df = \int_{-\frac{1}{2}}^{\frac{1}{2}} (1 - H_{\text{ótimo}}) P_s(f) df \\&= \int_{-\frac{1}{2}}^{\frac{1}{2}} \left(1 - \frac{P_s(f)}{P_s(f) + P_w(f)} \right) P_s(f) df \\&= \int_{-\frac{1}{2}}^{\frac{1}{2}} \frac{P_w(f)}{P_s(f) + P_w(f)} P_s(f) df \\&= \int_{-\frac{1}{2}}^{\frac{1}{2}} \frac{P_w(f) P_s(f)}{P_w(f) \left(\frac{P_s(f)}{P_w(f)} + 1 \right)} df \\&= \int_{-\frac{1}{2}}^{\frac{1}{2}} \frac{P_s(f)}{\left(\frac{P_s(f)}{P_w(f)} + 1 \right)} df\end{aligned}$$

Exemplo (cont.)

onde $\left(\frac{P_s(f)}{P_w(f)} + 1\right)$ é a relação sinal-ruído (SNR) no domínio da frequência.

$$\begin{array}{ccccc} SNR & \uparrow & MSE & \downarrow & \\ SNR & \downarrow & MSE & \rightarrow & P_s(f) \end{array}$$

Predição: Um passo à frente

$$\begin{aligned} MSE &= E \left[(x[n_0 + 1] - \hat{x}[n_0 + 1])^2 \right] \\ &= E \left[\left(x[n_0 + 1] - \sum_{k=0}^{\infty} h[k]x[n_0 - k] \right)^2 \right] \end{aligned}$$

Usando o princípio da ortogonalidade, temos:

Exemplo (cont.)

$$E \left[\left(x[n_0 + 1] - \sum_{k=0}^{\infty} h[k]x[n_0 + k] \right) x[n_0 - l] \right] = 0 \text{ para } l = 0, 1, \dots$$

logo

$$E [x[n_0 + 1] \times x[n_0 - l]] = \sum_{k=0}^{\infty} h[k] \times E [x[n_0 - k] \times x[n_0 - l]]$$

ou

$$r_X[l + 1] = \sum_{k=0}^{\infty} h[k] \times r_X[l - k]$$

repare que não depende de n_0 - serve para qualquer amostra.

O MSE é

Exemplo (cont.)

$$MSE_{\min} = r_X[0] - \sum_{k=0}^{\infty} h_{\text{ótimo}} r_X[k+1]$$

Exemplo: Predição de um processo AR

$$\begin{aligned} r_X[k] &= \frac{\sigma_U^2}{1-a^2} a^{|k|} \\ &= r_X[0] a^{|k|} \end{aligned}$$

logo

$$r_X[0] a^{|l+1|} = \sum_{k=0}^{\infty} h[k] r_X[0] a^{|l-k|}$$

Exemplo (cont.)

Considerando $h[k] = 0$ para $k \geq 1$, temos

$$a^{|l+1|} = h[0]a^{|l|}$$

e portanto

$$h[0] = \frac{a^{|l+1|}}{a^{|l|}} = a \text{ para } l \geq 0$$

ou seja,

$$\hat{x}[n_0 + 1] = ax[n_0]$$

Generalizando

$$\hat{x}[n] = ax[n-1]$$

- Lembrando que o AR é, por exemplo, $x[n] = ax[n-1] + u[n]$, vemos que a predição descarta $u[n]$.

- Repare que o erro é

$$e[n] = x[n] - \hat{x}[n] = u[n]$$

o que implica que $MSE \rightarrow \sigma_U^2$.

Sumário da Solução Geral

1) Transformada \mathcal{Z} da ACS

$$\begin{aligned}P_X(z) &= \sum_{k=-\infty}^{\infty} r_X[k]z^{-k} \\ &= \frac{\sigma_U^2}{A(z)A(z^{-1})}\end{aligned}$$

onde $A(z) = 1 - \sum_{k=1}^{\infty} a[k]z^{-k}$

2) A solução de $r_X[l+1] = \sum_{k=0}^{\infty} h[k]r_X[l-k]$ é

$$h_{\text{ótimo}}[k] = a[k+1] \quad k = 0, 1, \dots$$

e

$$MSE_{\min} = \sigma_U^2$$

Sumário da Solução Geral (cont.)

3) O Filtro Ótimo é

$$\hat{x}[n_0 + 1] = \sum_{k=0}^{\infty} a[k + 1]x[n_0 - k]$$

Olhando novamente para a PSD, temos

$$\begin{aligned} P_X(f) &= P_X(e^{j2\pi f}) = \frac{\sigma_U^2}{A(e^{j2\pi f})A(e^{-j2\pi f})} \\ &= \frac{\sigma_U^2}{A(e^{j2\pi f})A^*(e^{j2\pi f})} \\ &= \frac{\sigma_U^2}{|A(e^{j2\pi f})|^2} \\ &= \frac{\sigma_U^2}{|1 - \sum_{k=1}^{\infty} a[k]e^{-j2\pi f k}|^2} \end{aligned}$$

Se a PSD é truncada, ela toma a forma da PSD de um processo $AR(p)$:

$$P_X(f) = \frac{\sigma_U^2}{\left|1 - \sum_{k=1}^p a[k]e^{-j2\pi fk}\right|^2}$$

logo

$$\hat{x}[n_0 + 1] = \sum_{k=1}^p a[k]x[n_0 + 1 - k]$$

Exemplo - Predição

Predição de um passo à frente para o processo MA

- Cálculo de $H(z)$

$$\begin{aligned}x[n] &= u[n] - bu[n-1] \\ \downarrow \\ X(z) &= U(z) - bz^{-1}U(z) \\ &= \underbrace{(1 - bz^{-1})}_{H(z)} U(z)\end{aligned}$$

- A PSD é $H(f) \times H^*(f) \times \sigma_U^2$ ou

$$P_X(z) = (1 - bz^{-1})(1 - bz)\sigma_U^2$$

logo

$$A(z) = \frac{1}{1 - bz^{-1}}$$

Exemplo - Predição (cont.)

- Tomando a Transformada \mathcal{Z} inversa, temos

$$\mathcal{Z}^{-1}\{A(z)\} = \begin{cases} b^k, & k \geq 0 \\ 0, & k < 0 \end{cases}$$

com $|b| < 1$ para garantir estabilidade. Colocando na forma $1 - \sum_{k=1}^{\infty} a[k]z^{-k}$, temos

$$1 - \sum_{k=1}^{\infty} b^k z^{-k}$$

logo o preditor é

$$\hat{x}[n_0 + 1] = \sum_{k=0}^{\infty} -b^{k+1} x[n_0 - k]$$

Exemplo - Predição (cont.)

No caso finito

$$\hat{x}[n_0 + 1] = \sum_{k=0}^{M-1} -b^{k+1} x[n_0 - k]$$

logo

$$r_X[\ell + 1] = \sum_{k=0}^{M-1} h[k] r_X[\ell - k] \quad l = 0, 1, \dots, M - 1$$

que, na notação matricial, é

$$\begin{bmatrix} r_X[0] & r_X[1] & \dots & r_X[M-1] \\ \vdots & \ddots & \dots & \vdots \\ r_X[M-1] & \dots & \dots & r_X[0] \end{bmatrix} \begin{bmatrix} h[0] \\ \vdots \\ h[M-1] \end{bmatrix} = \begin{bmatrix} r_X[1] \\ \vdots \\ r_X[M] \end{bmatrix}$$

que são as **Equações de Wiener-Hopf**.

Filtro Rejeita Interferência

$$X(t) = S(t) + I(t)$$

onde $I(t)$ é uma interferência de 60 Hz com fase aleatória.

- Encontrar, se possível, um filtro que elimine a interferência sem afetar a PSD de S .

Solução: Filtro Diferença

$$Y(t) = X(t) - X(t - T)$$

onde T é conhecido, pois $T = \frac{1}{F_0} = \frac{1}{60}$.

- A função de transferência do filtro é

$$\begin{aligned} h(t) &= \delta(t) - \delta(t - T) \\ &\downarrow \\ H(F) &= (1 - e^{-j2\pi F T}) \end{aligned}$$

- A ACS da interferência é

$$\begin{aligned} r_I(\tau) &= \frac{A^2}{2} \cos(2\pi F_0 \tau) \\ &\downarrow \\ P_I(f) &= \frac{A^2}{4} \delta(F + F_0) + \frac{A^2}{4} \delta(F - F_0) \end{aligned}$$

A PSD é

$$\begin{aligned}P_Y(F) &= |H(F)|^2 \times P_X(F) \\&= |H(F)|^2 \times (P_S(F) + P_I(F)) \\&= |1 + e^{-j2\pi FT}|^2 \times (P_S(F) + P_I(F)) \\&= (2 - 2\cos(2\pi FT)) \times (P_S(F) + P_I(F))\end{aligned}$$

Para $F = \frac{1}{60}$

$$|H(F)|^2 = 0$$

o que elimina $P_I(F)$, mas a PSD, $P_S(F)$, é modificada!