

# Introdução aos Processos Estocásticos - Processos Estocásticos Gaussianos

Eduardo M. A. M. Mendes

DELT - UFMG  
Programa de Pós-Graduação em Engenharia Elétrica  
Universidade Federal de Minas Gerais  
[emmendes@cpdee.ufmg.br](mailto:emmendes@cpdee.ufmg.br)

## Muito importante na prática

- 1) Fisicamente justificável pelo TLC.
- 2) Matematicamente manipulável.
- 3) PDF conjunta de amostras  $\sim N(\mu, \sigma^2)$ .
- 4) Definida apenas por dois momentos.
  - a) Se os momentos podem ser estimados  $\rightarrow$  estimativa da pdf  $N(\bullet, \bullet)$ .
  - b) Se PA é WSS  $\rightarrow$  Estacionariedade.
- 5) A saída de um sistema linear cuja entrada é um PA gaussiano é também um PA gaussiano.

# Introdução (cont.)

Definição: Caso Discreto

$$\mathbf{X} = (X_1 \ X_2 \ \dots \ X_N)^T \sim N(\boldsymbol{\mu}, \mathbf{c})$$

A pdf é

$$p_{\mathbf{X}}(\mathbf{x}) = \frac{1}{(2\pi)^{\frac{N}{2}} \det^{\frac{1}{2}}(\mathbf{c}) e^{-\frac{1}{2}(\mathbf{x}-\boldsymbol{\mu})^T \mathbf{c}(\mathbf{x}-\boldsymbol{\mu})}}$$

onde

$$\boldsymbol{\mu} = E_{\mathbf{X}}[\mathbf{x}] = \begin{bmatrix} E_{X_1}(x_1) \\ \vdots \\ E_{X_N}(x_N) \end{bmatrix}$$

$$\begin{aligned} \mathbf{c} &= E_{\mathbf{X}} \left[ (\mathbf{X} - E_{\mathbf{X}}[\mathbf{x}])(\mathbf{X} - E_{\mathbf{X}}[\mathbf{x}])^T \right] \\ &= \begin{bmatrix} \text{Var}(X_1) & \text{cov}(X_1, X_2) & \dots & \text{cov}(X_1, X_N) \\ \vdots & \text{Var}(X_2) & \vdots & \vdots \\ \vdots & \vdots & \ddots & \vdots \\ \text{cov}(X_N, X_1) & \dots & \dots & \text{Var}(X_N) \end{bmatrix} \end{aligned}$$

# Introdução (cont.)

- 1) Somente os dois primeiros momentos  $\mu$  e  $\mathbf{c}$ .
- 2) Se VAs são não correlacionadas  $\rightarrow \mathbf{c}$  é diagonal  $\rightarrow$  VAs independentes.
- 3)  $\mathbf{Y} = \underbrace{\mathbf{G}}_{M \times N, M \leq N} \mathbf{X} \rightarrow \mathbf{Y} \sim N(\mathbf{G}\mu, \mathbf{GCG}^T)$

**Exemplo:** WGN definido IID com  $X[n] \sim N(0, \sigma^2)$  e  $X$  com dimensão  $K$ .

$$\begin{aligned} p_{\mathbf{x}}(\mathbf{x}) &= \prod_{i=1}^K p_X[x_i](X[x_i]) \\ &= \prod_{i=1}^K \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2\sigma^2} X^2[n_i]} \\ &= \frac{1}{(2\pi\sigma^2)^{\frac{K}{2}}} e^{-\frac{1}{2\sigma^2} \mathbf{x}^T \mathbf{x}} \\ &= \frac{1}{(2\pi)^{\frac{K}{2}} \det^{\frac{1}{2}}(\sigma^2 \mathbf{I})} e^{-\frac{1}{2} \mathbf{x}^T (\sigma^2 \mathbf{I})^{-1} \mathbf{x}} \end{aligned}$$

ou simplesmente  $N(\mathbf{0}, \sigma^2 \mathbf{I})$ , ruído gaussiano branco (WGN).

# Introdução (cont.)

Exemplo:

$$X[n] = \frac{1}{2} (U[n] + U[n-1])$$

onde  $U[n]$  é WGN com variância  $\sigma_U^2$ . Para mostrar que é um PA gaussiano considere

$$K = 2, n_1 = 0, n_2 = 1$$

logo

$$\underbrace{\begin{bmatrix} X[0] \\ X[1] \end{bmatrix}}_{\mathbf{X}} = \underbrace{\begin{bmatrix} \frac{1}{2} & \frac{1}{2} & 0 \\ 0 & \frac{1}{2} & \frac{1}{2} \end{bmatrix}}_{\mathbf{G}} \underbrace{\begin{bmatrix} U[-1] \\ U[0] \\ U[1] \end{bmatrix}}_{\mathbf{U}}$$

$$\text{ou } \mathbf{X} \sim N(\mathbf{0}, \mathbf{G} \mathbf{c}_U \mathbf{G}^T) = N(\mathbf{0}, \sigma_U^2 \mathbf{G} \mathbf{G}^T).$$

Para  $n_1 = n_0$  e  $n_2 = n_0 + 1$

$$\begin{bmatrix} X[n_0] \\ X[n_0 + 1] \end{bmatrix} = \begin{bmatrix} \frac{1}{2} & \frac{1}{2} & 0 \\ 0 & \frac{1}{2} & \frac{1}{2} \end{bmatrix} \begin{bmatrix} U[n_0 - 1] \\ U[n_0] \\ U[n_0 + 1] \end{bmatrix}$$

que leva ao mesmo resultado.

Transformação Linear de **U** produz outro vetor aleatório gaussiano, ou seja,  $X[n]$  é um PA gaussiano.

$$U[n] \rightarrow \underbrace{\left[ \frac{1}{2} + \frac{1}{2}z^{-1} \right]}_{\text{Filtro Suavizador}} \rightarrow X[n] = \frac{1}{2}U[n] + \frac{1}{2}U[n-1]$$

Por exemplo, se o filtro é realmente um suavizador

$$P(X[1] - X[0] > 1) < P(U[1] - U[0] > 1)$$

# Introdução (cont.)

mas

$$P(U[1] - U[0]) \sim N(0, 2)$$

pois  $U[n] \sim N(0, 1)$  e independente.

Logo

$$P(U[1] - U[0]) = Q\left(\frac{1-0}{\sqrt{2}}\right) = Q\left(\frac{1}{\sqrt{2}}\right) = 0,2398$$

Para encontrar  $P(X[1] - X[0] > 1)$  seja  $y = X[1] - X[0]$ .

$$y = \underbrace{\begin{bmatrix} -1 & 1 \end{bmatrix}}_{\mathbf{A}} \underbrace{\begin{bmatrix} X[0] \\ X[1] \end{bmatrix}}_{\mathbf{X}} \sim N(\mathbf{A}E[\mathbf{X}], \mathbf{A}\mathbf{c}_X\mathbf{A}^T)$$

com  $\mathbf{A}E[\mathbf{X}] = \mathbf{0}$  ( $X[n]$  tem média zero).

$$\text{Var}(\mathbf{Y}) = \mathbf{A}\mathbf{c}_X\mathbf{A}^T = \begin{bmatrix} -1 & 1 \end{bmatrix} \mathbf{c}_X \begin{bmatrix} -1 \\ 1 \end{bmatrix}$$



# Introdução (cont.)

mas

$$\underbrace{\begin{bmatrix} X[0] \\ X[1] \end{bmatrix}}_{\mathbf{X}} = \underbrace{\begin{bmatrix} \frac{1}{2} & \frac{1}{2} & 0 \\ 0 & \frac{1}{2} & \frac{1}{2} \end{bmatrix}}_{\mathbf{G}} \underbrace{\begin{bmatrix} U[-1] \\ U[0] \\ U[1] \end{bmatrix}}_{\mathbf{U}}$$

logo

$$\begin{aligned} \mathbf{c}_X &= \mathbf{G} \mathbf{c}_U \mathbf{G}^T = \mathbf{G} \sigma_U^2 / \mathbf{G}^T \\ &= \mathbf{G} \mathbf{G}^T \\ &= \begin{bmatrix} \frac{1}{2} & \frac{1}{2} & 0 \\ 0 & \frac{1}{2} & \frac{1}{2} \end{bmatrix} \begin{bmatrix} \frac{1}{2} & 0 \\ \frac{1}{2} & \frac{1}{2} \\ 0 & \frac{1}{2} \end{bmatrix} \\ &= \begin{bmatrix} \frac{1}{2} & \frac{1}{4} \\ \frac{1}{4} & \frac{1}{2} \end{bmatrix} \end{aligned}$$

e

$$\text{Var}(\mathbf{Y}) = \begin{bmatrix} -1 & 1 \end{bmatrix} \begin{bmatrix} \frac{1}{2} & \frac{1}{4} \\ \frac{1}{4} & \frac{1}{2} \end{bmatrix} \begin{bmatrix} -1 \\ 1 \end{bmatrix} = \frac{1}{2}$$

o que implica em  $Y \sim N(0, \frac{1}{2})$ .

$$\begin{aligned} P(X[1] - X[0] > 1) &= P(Y > 1) = Q\left(\frac{1 - 0}{\sqrt{\frac{1}{2}}}\right) \\ &= Q(\sqrt{2}) \\ &= 0,0786 < 0,2398 = P(U[1] - U[0]) \end{aligned}$$

# Processo Wiener em Tempo Discreto

Movimento Browniano = Passeio Aleatório com passos gaussianos

$$X[n] = \sum_{i=0}^n U[i] \quad n \geq 0$$

onde  $U[n]$  é WGN com variância  $\sigma_U^2$ .




Figura 1: Realização de Processo Wiener

# Processo Wiener em Tempo Discreto (cont.)

- Qualquer conjunto de amostras é uma transformação linear de  $U[i]$ s o que resulta em um PA gaussiano.
- A variância é

$$\text{Var}(X[n]) = (n + 1)\sigma_U^2$$

ou seja, um processo não-estacionário.

Propriedades de um PA Gaussiano

- 1) Se as amostras são não-correlacionadas - independência.
- 2) Se um PA Gaussiano é WSS - estacionário no sentido restrito

Transformações Lineares - Novos PAs Gaussianos podem ser definidos como saída de filtros LTI com entradas gaussianas

- Filtro MA

$$U[n] \rightarrow \left[ \frac{1}{2} + \frac{1}{2}z^{-1} \right] \rightarrow X[n]$$

- Filtro AR

$$U[n] \rightarrow \left[ \frac{1}{1 - az^{-1}} \right] \rightarrow X[n]$$

$$X[n] = aX[n-1] + U[n] \quad \text{com } |a| < 1$$

- Filtro MA

$$U[n] \rightarrow \boxed{1 - bz^1} \rightarrow X[n]$$

$$X[n] = U[n] - bU[n-1]$$

- Filtro ARMA

$$U[n] \rightarrow \boxed{\frac{1 - bz^{-1}}{1 - az^{-1}}} \rightarrow X[n]$$

$$X[n] = aX[n-1] + U[n] - bU[n-1] \text{ com } |a| < 1$$

ou na forma geral

$$\rightarrow \boxed{\frac{1 - b(1)z^{-1} - b(2)z^{-2} - \dots - b(q)z^{-q}}{1 - a(1)z^{-1} - a(2)z^{-2} - \dots - a(p)z^{-p}}} \rightarrow$$

$$X[n] = \sum_{k=1}^p a[k]X[n-k] + U[n] - \sum_{k=1}^q b[k]U[n-k]$$

um ARMA( $p, q$ ), onde  $U[n]$  é WGN com variância  $\sigma_U^2$ .

# Exemplos

Em geral assumimos que  $X[n]$  é gaussiano e WSS com média  $\mu_X$  e ACS  $r_X[k]$

$$\underbrace{X[n]}_{\text{Gaussiano WSS}} \rightarrow \boxed{H(f)} \rightarrow \underbrace{Y[n]}_{\text{Gaussiano WSS}}$$

$$Y[n] \rightarrow \begin{cases} \mu_Y & = \mu_X H(0) \\ P_Y(f) & = |H(f)|^2 \times P_X(f) \end{cases}$$

Exemplo: ARMA

$$\begin{aligned} \mu_X &= \underbrace{\mu_U}_{=0} H(0) = 0 \\ P_X(f) &= |H(f)|^2 \times P_U(f) \\ &= |H(e^{j2\pi f})|^2 \times \sigma_U^2 \\ &= \sigma_U^2 \frac{|1 - b(1)e^{-j2\pi f} - \dots - b(q)e^{j2\pi fq}|^2}{|1 - a(1)e^{-j2\pi f} - \dots - a(p)e^{j2\pi fp}|^2} \end{aligned}$$



# Exemplos (cont.)

**Exemplo:** Diferenciador - (remover o sinal DC)

$$X[n] \rightarrow \boxed{1 - z^{-1}} \rightarrow Y[n] = X[n] - X[n - 1]$$

onde  $X[n]$  é um PA WSS Gaussiano com  $\mu_X$  e  $r_X[k]$ . Qual é a PDF de  $Y = \begin{bmatrix} Y[0] \\ Y[1] \end{bmatrix}$ ?

**Solução**

$$\begin{aligned} \mu_Y &= E[Y[n]] \\ &= E[X[n] - X[n - 1]] \\ &= \mu_X - \mu_X = 0 \text{ (sem nível DC)} \end{aligned}$$

## Exemplos (cont.)

e

$$\begin{aligned}\mathbf{c}_Y &= \begin{bmatrix} E[Y[0]Y[0]] & E[Y[0]Y[1]] \\ E[Y[1]Y[0]] & E[Y[1]Y[1]] \end{bmatrix} \\ &= \begin{bmatrix} r_Y[0] & r_Y[1] \\ r_Y[1] & r_Y[0] \end{bmatrix} \text{ é WSS}\end{aligned}$$

Mas

$$\begin{aligned}P_Y(f) &= |H(f)|^2 \times P_X(f) \\ &= H(f) \times H^*(f) \times P_X(f) \\ &= (1 - e^{-j2\pi f})(1 - e^{j2\pi f})P_X(f) \\ &= 2P_X(f) - e^{j2\pi f}P_X(f) - e^{-j2\pi f}P_X(f)\end{aligned}$$

## Exemplos (cont.)

Tomando a transformada de Fourier inversa

$$r_Y[k] = 2r_X[k] - r_X[k+1] - r_X[k-1]$$

$$\mathbf{c}_Y = \begin{bmatrix} r_Y[0] & r_Y[1] \\ r_Y[1] & r_Y[0] \end{bmatrix} = \begin{bmatrix} 2(r_X[0] - r_X[1]) & 2r_X[1] - r_X[2] - r_X[0] \\ 2r_X[1] - r_X[2] - r_X[0] & 2(r_X[0] - r_X[1]) \end{bmatrix}$$

Logo a pdf conjunta é

$$P_{Y[0], Y[1]}(y[0], y[1]) = \frac{1}{2\pi^{\frac{1}{2}} \det^{\frac{1}{2}}(\mathbf{c}_Y)} e^{-\frac{1}{2} \mathbf{y}^T \mathbf{c}_Y^{-1} \mathbf{y}}$$

# Transformações Não-Lineares

Em geral é difícil achar a pdf do PA  $Y[n] = X[n] + \frac{1}{2}X^2[n]$  para

$$\mathbf{Y} = [y[n_1] \quad y[n_2] \quad \cdots \quad y[n_k]]^T$$

Se  $X[n]$  é gaussiano, **podemos pelo menos achar os momentos** de  $Y[n]$ .

Exemplo:

$$\begin{aligned} E[Y[0]Y[1]] &= E \left[ \left( X[0] + \frac{1}{2}X^2[0] \right) \times \left( X[1] + \frac{1}{2}X^2[1] \right) \right] \\ &= E[X[0]X[1]] + \frac{1}{2}E[X[0]X^2[1]] + \\ &\quad \frac{1}{2}E[X^2[1]X[0]] + E[X^2[0]X^2[1]] \end{aligned}$$

repare que o termo  $E[X^2[0]X^2[1]]$  é de 4ª ordem!

# Transformações Não-Lineares (cont.)

Repare

$$E\left(X_1^{\ell_1} X_2^{\ell_2} \cdots X_N^{\ell_N}\right) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} X_1^{\ell_1} X_2^{\ell_2} \cdots X_N^{\ell_N} p_{X_1, X_2, \dots, X_N}(X_1 \cdots X_N) dX_1 \cdots dX_N$$

que trata com uma pdf gaussiana multivariada, função do 1º e 2º momentos.

**Resultado Interessante:** Se  $\mathbf{X} = [X_1 \ X_2 \ X_3 \ X_4]^T \sim N(\mathbf{0}, \mathbf{c})$ , então

$$\begin{aligned} E[X_1 X_2 X_3 X_4] &= E[X_1 X_2] E[X_3 X_4] + \\ &\quad E[X_1 X_3] E[X_2 X_4] + E[X_1 X_4] E[X_2 X_3] \end{aligned}$$

Se  $X[n]$  é um PA Gaussiano com média zero

# Transformações Não-Lineares (cont.)

$$\begin{aligned} E[X[n_1]X[n_2]X[n_3]X[n_4]] &= E[X[n_1]X[n_2]] \times E[X[n_3]X[n_4]] + \\ &E[X[n_1]X[n_3]] \times E[X[n_2]X[n_4]] + \\ &E[X[n_1]X[n_4]] \times E[X[n_2]X[n_3]] \end{aligned}$$

só é preciso o segundo momento.  
Se  $X[n]$  é também WSS

$$\begin{aligned} E[X[n_1]X[n_2]X[n_3]X[n_4]] &= r_X[n_2 - n_1] \times r_X[n_4 - n_3] + \\ &r_X[n_3 - n_1] \times r_X[n_4 - n_2] + \\ &r_X[n_4 - n_1] \times r_X[n_3 - n_2] \end{aligned}$$

# Transformações Não-Lineares (cont.)

**Exemplo:** Quadrado de um PA Gaussiano WSS

$$X[n] \rightarrow \boxed{(\ )^2} \rightarrow Y[n] = X^2[n]$$

onde  $X[n]$  tem média zero.

**Solução**

$$E[Y[n]] = E[X^2[n]] = r_X[0] = \mu_Y$$

$$\begin{aligned} E[Y[n]Y[n+k]] &= E[X^2[n] \times X^2[n+k]] \\ &= E[X[n]X[n]X[n+k]X[n+k]] \\ &= r_X[0] \times r_X[0] + r_X[k]r_X[k] + r_X[k] \times r_X[k] \\ &= r_X^2[0] + 2r_X^2[k] \quad \text{que não depende de } n \end{aligned}$$

# Transformações Não-Lineares (cont.)

$Y[n]$  é WSS com

$$\begin{aligned}\mu_Y &= r_X[0] \\ r_Y[k] &= r_X^2[0] + 2r_X^2[k] \\ P_Y(f) &= \mathcal{F}\{r_Y[k]\} = r_X^2[0]\delta(f) + 2 \underbrace{P_X(f) * P_X(f)}_{\int_{-\frac{1}{2}}^{\frac{1}{2}} P_X(v)P_X(t-v)dv}\end{aligned}$$



# Transformações Não-Lineares (cont.)

Considere, agora, que  $X[n]$  é um PA MA, ou seja

$$X[n] = \frac{1}{2}(U[n] - U[n-1]) \text{ com } \sigma_U^2 = 1$$

Sabemos que

$$r_X[k] = \frac{1}{2}\delta[k] + \frac{1}{4}\delta[k+1] + \frac{1}{4}\delta[k-1]$$

Logo

# Transformações Não-Lineares (cont.)

$$\begin{aligned}\mu_Y &= r_X[0] = \frac{1}{2} \\ r_Y[k] &= r_X^2[0] + 2r_X^2[k] \\ &= \frac{1}{4} + 2 \left( \frac{1}{2}\delta[k] + \frac{1}{4}\delta[k-1] + \frac{1}{4}\delta[k+1] \right)^2 \\ &= \frac{1}{4} + \frac{1}{2}\delta[k] + \frac{1}{8}\delta[k-1] + \frac{1}{8}\delta[k+1] \\ P_Y(f) &= \frac{1}{4}\delta(f) + \frac{1}{2} + \frac{1}{8}(e^{-j2\pi f} + e^{j2\pi f}) \\ &= \frac{1}{4}\delta(f) + \underbrace{\frac{1}{2} + \frac{1}{4}\cos(2\pi f)}_{\text{Comparar com a PSD de } x} \quad \text{com } |f| \leq \frac{1}{2}\end{aligned}$$

# Transformações Não-Lineares (cont.)




Figura 2: Quadrado de um PA Gaussiano WSS

# Processo Aleatório Gaussiano em Tempo Contínuo

Considere

$$X(t) \quad -\infty < t < \infty$$

$X(t)$  é gaussiano se

$$\mathbf{x} = (x(t_1), x(t_2), \dots, x(t_r))^T$$

tem pdf gaussiana multivariada para todo  $k$  e todo  $\{t_1, \dots, t_k\}$ .

**Exemplo:** PA Wiener em Tempo Contínuo (Movimento Browniano)

$$X(t) = \int_0^t U(\tau) d\tau \quad t \geq 0$$

onde  $U(t)$  é WGN CT com  $r_U(\tau) = \frac{N_0}{2} \delta(\tau)$ .

# Processo Aleatório Gaussiano em Tempo Contínuo (cont.)

Repare que os incrementos, por exemplo  $X(t_2) - X(t_1)$ , são independentes e estacionários.

- Se  $X(t)$  é gaussiano, precisamos provar que a “soma não-contável” de VAS gaussianas é gaussiana.

- Precisamos achar somente a média e a covariância

$$\begin{aligned} E(X(t)) &= E\left(\int_0^t U(\tau) d\tau\right) \\ &= \int_0^t E(U(\tau)) d\tau = 0 \end{aligned}$$

$$\begin{aligned} E(X(t_1)X(t_2)) &= E\left(\int_0^{t_1} U(\tau_1) d\tau_1 \int_0^{t_2} U(\tau_2) d\tau_2\right) \\ &= \int_0^{t_1} \int_0^{t_2} \underbrace{E(U(\tau_1) \times U(\tau_2))}_{r_U(\tau_2 - \tau_1) = \frac{N_o}{2} \delta(\tau_2 - \tau_1)} d\tau_1 d\tau_2 \\ &= \frac{N_o}{2} \int_0^{t_1} \left(\int_0^{t_2} \delta(\tau_2 - \tau_1) d\tau_2\right) d\tau_1 \end{aligned}$$

# Processo Aleatório Gaussiano em Tempo Contínuo (cont.)

Para que o impulso dispare é preciso que  $t_2$  seja maior do que  $t_1$ . Logo

$$E(X(t_1) \times X(t_2)) = \frac{N_o}{2} \int_0^{t_1} d\tau_1 = \frac{N_o}{2} t_1 \text{ para } t_2 > t_1$$

e

$$E(X(t_1) \times X(t_2)) = \frac{N_o}{2} \int_0^{t_2} d\tau_2 = \frac{N_o}{2} t_2$$

ou

$$E(X(t_1) \times X(t_2)) = \frac{N_o}{2} \min(t_1, t_2)$$

O PA Wiener  $X(t) \sim N(0, \frac{N_o}{2} t)$  é não-estacionário.

# Rayleigh Fading Sinusoid

Neste caso temos

- Amplitude Aleatória e
- Fase Aleatória

**Exemplo:** Senoide transmitida é recebida no destino a partir de caminhos múltiplos (Interferência Construtiva e Destrutiva) - **Multipath Fading**.



# Rayleigh Fading Sinusoid (cont.)




Figura 3: Exemplo de segmento de sinal num curto período de tempo

Considere o seguinte modelo para um período curto de tempo

$$X(t) = \underbrace{A}_{\text{VA: } A > 0} \cos(2\pi F_0 t + \underbrace{\theta}_{\text{VA: } 0 < \theta < 2\pi})$$

Qual é a PDF para  $A$  e  $\theta$ ?

## Rayleigh Fading Sinusoid (cont.)

$$\begin{aligned} X(t) &= \underbrace{A \cos(\theta)}_{=U} \cos(2\pi F_o t) - \underbrace{A \sin(\theta)}_{=V} \sin(2\pi F_o t) \\ &= U \cos(2\pi F_o t) - V \sin(2\pi F_o t) \end{aligned}$$

Usando o TLC, podemos supor que

$$U \sim N(0, \sigma^2) \quad \text{e} \quad V \sim N(0, \sigma^2)$$

Repare que

$$E(U) = E(V) = 0 \implies E(X) = 0$$

ou seja, com  $U$  e  $V$  considerados independentes,  $X(t)$  está relacionado com um PA Gaussiano com média zero.

## Rayleigh Fading Sinusoid (cont.)

$$\begin{bmatrix} X(t_1) \\ \vdots \\ X(t_k) \end{bmatrix} = \begin{bmatrix} \cos(2\pi F_0 t_1) & -\sin(2\pi F_0 t_1) \\ \vdots & \vdots \\ \cos(2\pi F_0 t_k) & -\sin(2\pi F_0 t_k) \end{bmatrix} \begin{bmatrix} U \\ V \end{bmatrix}$$

como  $U \sim N(0, \sigma^2)$  e  $V \sim N(0, \sigma^2)$  resulta em  $\begin{bmatrix} U \\ V \end{bmatrix}$  com PDF Gaussiana Multivariada.

$X$  é uma transformação de uma PDF Gaussiana Multivariada

com

- $A = \sqrt{U^2 + V^2} \sim \text{Rayleigh},$
- $\theta = \arctan\left(\frac{U}{V}\right) \sim U(0, 2\pi)$

# Rayleigh Fading Sinusoid (cont.)

Mas  $X(t)$  é WSS?

$$E(U) = E(V) \implies E(X(t)) = 0$$

e

$$\begin{aligned} E(X(t)X(t+\tau)) &= E((U\cos(2\pi F_0 t) - V\sin(2\pi F_0 t)) \times \\ &\quad (U\cos(2\pi F_0(t+\tau)) - V\sin(2\pi F_0(t+\tau)))) \\ &= E(U^2)\cos(2\pi F_0 t)\cos(2\pi F_0(t+\tau)) + \\ &\quad E(V^2)\sin(2\pi F_0 t)\sin(2\pi F_0(t+\tau)) \\ &= \sigma^2 \cos(2\pi F_0 t)\cos(2\pi F_0(t+\tau)) + \sigma^2 \sin(2\pi F_0 t)\sin(2\pi F_0(t+\tau)) \\ &= \sigma^2 \cos(2\pi F_0 \tau) \text{ que não depende de } t \end{aligned}$$

logo  $X(t)$  é WSS.

E a PSD?

## Rayleigh Fading Sinusoid (cont.)

$$P_X(F) = \mathcal{F}\{r_X(\tau)\} = \frac{\sigma^2}{2}\delta(F + F_0) + \frac{\sigma^2}{2}\delta(F - F_0)$$

# Processo Aleatório Gaussiano Passa-Faixa

O procedimento anterior foi considerado por um tempo curto, mas com o passar do tempo a amplitude de senoide muda, ou seja, o modelo seria ainda melhor se considerássemos  $A$  e  $\theta$  variando com o tempo.

$$x(t) = \underbrace{A(t)}_{\text{modulação em amplitude}} \cos(2\pi F_0 t + \underbrace{\theta(t)}_{\text{modulação em fase}})$$

onde  $x(t)$  é um processo aleatório passa-faixa.

Usando a mesma idéia, temos

$$x(t) = \underbrace{A(t)\cos(\theta(t))}_{=U(t)} \cos(2\pi F_0 t) - \underbrace{A(t)\sin(\theta(t))}_{=V(t)} \sin(2\pi F_0 t)$$

Supondo que  $U(t)$  e  $V(t)$  são PAs Gaussianos e independentes um do outro

$$p_{\mathbf{U},\mathbf{V}} = p_{\mathbf{U}} \times p_{\mathbf{V}}$$

# Processo Aleatório Gaussiano Passa-Faixa (cont.)

Para que  $E(X(t)) = 0$ , precisamos assumir que  $E(U(t)) = 0 = E(V(t))$  para todo  $t$ .

Para  $X(t)$  ser WSS, assumimos que  $U(t)$  e  $V(t)$  são WSS e têm ACF  $r_U(\tau) = r_V(\tau)$ , logo

$$\begin{aligned} r_X(\tau) &= E(X(t)X(t+\tau)) \\ &= E((U(t)\cos(2\pi F_0 t) - U(t)\sin(2\pi F_0 t)) \times \\ &\quad (U(t+\tau)\cos(2\pi F_0(t+\tau)) - U(t+\tau)\sin(2\pi F_0(t+\tau)))) \\ &= r_U(\tau)\cos(2\pi F_0 t)\cos(2\pi F_0(t+\tau)) + \\ &\quad r_V(\tau)\sin(2\pi F_0 t)\sin(2\pi F_0(t+\tau)) \\ &= r_U(\tau)\cos(2\pi F_0 \tau) \text{ considerando } r_U(\tau) = r_V(\tau) \end{aligned}$$

# Processo Aleatório Gaussiano Passa-Faixa (cont.)

$$P_X(f) = \frac{1}{2}P_U(F + F_0) + \frac{1}{2}P_U(F - F_0)$$




Figura 4: Modulação

Considerando simetria  $P_U(F) = P_V(F)$  em torno do zero.



# Processo Aleatório Gaussiano Passa-Faixa (cont.)




Figura 5: Modulação




Figura 6: Filtro Passa-Faixa

$$P_U(F) = P_V(F) = \begin{cases} N_o & |F| < \frac{W}{2} \\ 0 & |F| > \frac{W}{2} \end{cases}$$

$$r_U(\tau) = r_V(\tau) = N_o W \frac{\text{sen}(\pi W \tau)}{\pi W \tau}$$

# WGN Passa-Faixa (cont.)




Figura 7: Realizações de ruído

$$A(t) = \sqrt{U^2(t) + V^2(t)}$$

espera-se que o envelope seja não-correlacionado para  $\tau = \Delta t > \frac{1}{W}$ .